

COMPTE RENDU :

SAE Estimation par échantillonnage

Titulaire : M. ORSI

Groupe 11

BUT Science des données

Variable étudiée : Vmag

Numéro du fichier : VMAG_30_1 et VMAG_100_1

Enzo CHEN

Michael DAI

Hugo MA



Introduction

Dans le cadre de la SAE *Estimation par échantillonnage*, notre groupe a mené une étude statistique sur un jeu de données concernant les étoiles (issu du fichier Star39552_balanced.csv), dans le but d'estimer des paramètres de population à partir d'échantillons de tailles réduites, l'un de taille 30 (vmag30_1.txt) et l'autre de taille 100 (vmag100_1.txt). L'objectif principal de cette analyse est de vérifier, à l'aide de méthodes d'inférence statistique, si la **magnitude apparente moyenne** des étoiles est égale à une valeur donnée, ici **8**, en travaillant sur deux échantillons indépendants.

Le jeu de données utilisé contient **39 552 observations** (étoiles) et **7 variables** :

- Vmag : la **magnitude apparente** de l'étoile (c'est la variable quantitative continue que nous étudions dans ce travail),
- Plx : la parallaxe de l'étoile,
- e_Plx : l'erreur sur la parallaxe,
- B.V : l'indice de couleur (B-V),
- SpType : le type spectral de l'étoile (variable qualitative),
- Amag : la magnitude absolue,
- TargetClass : une classe cible indiquant une catégorisation (0 ou 1).

La variable centrale de notre étude est donc **Vmag**, la magnitude apparente, qui indique la **luminosité perçue** d'une étoile depuis la Terre. Nous cherchons à savoir si, en moyenne, cette grandeur est effectivement égale à 8, comme le suppose l'hypothèse nulle de nos tests statistiques.

Ce compte rendu est structuré en deux grandes parties :

- Dans un premier temps, nous analysons un **échantillon de taille 30**,
- Puis dans un second temps, nous reprenons les mêmes étapes sur un **échantillon de taille 100**, afin de comparer les résultats selon la taille de l'échantillon.

Chaque analyse inclura une étude descriptive, des **intervalles de confiance**, des **tests d'hypothèses**, ainsi qu'une **visualisation de la loi de test**, afin de proposer une interprétation rigoureuse des résultats.

Partie 1 : Analyse de l'échantillon de taille 30

1. Présentation de l'échantillon et statistiques descriptives

Nous travaillons sur un échantillon aléatoire de taille 30 extrait de la population complète, qui compte 39 552 étoiles. La variable étudiée est la **magnitude apparente (Vmag)**, qui représente la luminosité perçue d'une étoile depuis la Terre.

La moyenne théorique de cette variable dans la population entière est : $\mu=7.9213$

Les principales caractéristiques statistiques de l'échantillon de taille 30 montrent une moyenne de 7,867, une médiane de 8,165, une variance de 1,9339 et un écart-type de 1,3906, avec des valeurs allant de 2,860 à 10,250 et des quartiles à 7,397 (Q1) et 8,672 (Q3).

Le boxplot et l'histogramme réalisés confirment que la distribution des valeurs est légèrement centrée autour de 8.

2. Construction des intervalles de confiance (IC)

Nous construisons des intervalles de confiance à 95% et 99% pour la moyenne de Vmag, en utilisant la statistique t de Student avec 29 degrés de liberté.

- Intervalles de confiance obtenus : IC95%=[7.348,8.387], IC99%=[7.168,8.567]

Ces intervalles contiennent tous deux la valeur hypothétique $\mu_0=8$, ce qui suggère que la moyenne vraie pourrait être égale à 8.

3. Test d'hypothèse sur la moyenne

On teste l'hypothèse nulle $H_0 : \mu=8$

- Statistique de test calculée :
- $t_{\text{obs}} = (7.867 - 8) / (1.3906 / \sqrt{30}) = -0.523$
- Quantiles : $t_{0.975} = \pm 2.045$, $t_{0.995} = \pm 2.756$
- p-valeur associée : $p=0.6053$

Puisque $-2.045 < t_{\text{obs}} < 2.045$ et $p > 0.05$, nous **ne rejetons pas** H_0 au niveau de 5%. De même, au seuil plus strict de 1%, le test confirme le non-rejet.

4. Vérification par les intervalles de confiance

L'analyse de la position de $\mu_0=8$ dans les intervalles de confiance confirme le test :

- À 95 % : $\mu_0 = 8$ appartient à IC95 % → on ne rejette pas H_0 .
- À 99 % : $\mu_0 = 8$ appartient à IC99 % → on ne rejette pas H_0 .

5. Validation avec la fonction R t.test

La fonction t.test appliquée sur l'échantillon confirme ces résultats, affichant une moyenne proche de 7.867, des intervalles de confiance identiques et une p-valeur de 0.6053, indiquant un échec au rejet de l'hypothèse nulle.

6. Visualisation de la statistique de test

Le graphique de la densité de la loi de Student (29 degré de liberté) montre en rouge les quantiles pour alpha à 5% et en bleu la valeur observée de la statistique $t_{obs} = -0.523$. La statistique se situe bien à l'intérieur de la zone de non-rejet, ce qui illustre graphiquement notre conclusion.

Conclusion partielle de la partie 1 :

À partir de l'échantillon de taille 30, nous avons estimé la moyenne de la variable Vmag et construit des intervalles de confiance aux niveaux 95 % et 99 %. Ces intervalles nous permettent d'évaluer la compatibilité de la valeur théorique $\mu = 8$ avec les données observées. On remarque que l'intervalle à 99 % est plus large que celui à 95 %, ce qui s'explique par le fait qu'un niveau de confiance plus élevé réduit le risque d'erreur (1 % contre 5 %), mais au prix d'un intervalle plus étendu. Graphiquement, l'intervalle à 95 % est inclus dans celui à 99 %, ce qui signifie qu'en choisissant un niveau de confiance plus faible, on accepte une plus grande probabilité de se tromper. Toutefois, dans notre cas, la valeur $\mu = 8$ est incluse dans les deux intervalles, ce qui indique qu'elle reste compatible avec les données, que l'on fixe le risque à 5 % ou à 1 %. En réalisant un test de comparaison de moyenne, la statistique de test et la p-valeur confirment cette interprétation : pour les deux niveaux de risque, nous n'avons pas de raison de rejeter l'hypothèse nulle. La représentation graphique de la densité de la loi t sous H_0 illustre également la position de la statistique de test par rapport aux bornes critiques, ce qui renforce visuellement la décision de ne pas rejeter H_0 .

Cette première analyse sur un petit échantillon met en évidence la compatibilité de la valeur 8 avec les données. Nous allons maintenant observer si cette conclusion se confirme avec un échantillon plus grand, ce qui pourrait améliorer la précision des estimations.

Partie 2 : Analyse de l'échantillon de taille 100

1. Présentation de l'échantillon et statistiques descriptives

Nous analysons maintenant un second échantillon, plus grand, de taille 100, issu de la même population de 39 552 étoiles. La variable étudiée reste la magnitude apparente (**Vmag**).

Les statistiques descriptives de cet échantillon sont : minimum 4,390, premier quartile 7,110, médiane 8,205, moyenne 7,846, troisième quartile 8,840, maximum 9,800, variance 1,4811 et écart-type 1,2170.

Les représentations graphiques (boxplot et histogramme) confirment une distribution centrée autour de 7.8–8.0, avec une dispersion moindre que dans le premier échantillon.

2. Construction des intervalles de confiance (IC)

Pour cet échantillon, nous construisons également des intervalles de confiance à 95% et 99% en utilisant la loi t de Student avec 99 degrés de liberté.

- Quantiles t calculés :
- $t_{0.975,99} = 1.984$, $t_{0.995,99} = 2.626$
- Intervalles de confiance obtenus : $IC_{95\%} = [7.605, 8.088]$, $IC_{99\%} = [7.527, 8.166]$

Ces intervalles contiennent également la valeur hypothétique $\mu_0=8$, indiquant une forte probabilité que la vraie moyenne soit proche de 8.

3. Test d'hypothèse sur la moyenne

Nous testons encore l'hypothèse nulle $H_0: \mu=8$.

- Statistique de test calculée :
- $t_{obs} = (7.846 - 8) / (1.217 / \sqrt{100}) = -1.262$
- Quantiles: $t_{0.975} = \pm 1.984$, $t_{0.995} = \pm 2.626$
- p-valeur associée : $p=0.2099$

La statistique observée t_{obs} est comprise entre les quantiles critiques et la p-valeur est bien supérieure à 0.05. Nous **ne rejetons pas** H_0 au niveau de 5%, ni au niveau de 1%.

4. Vérification par les intervalles de confiance

L'hypothèse $\mu_0=8$ appartient aux deux intervalles de confiance :

- À 95 % : μ_0 appartient à l'intervalle de confiance à 95 % → on ne rejette pas H_0 .
- À 99 % : μ_0 appartient à l'intervalle de confiance à 99 % → on ne rejette pas H_0

5. Validation avec la fonction R t.test

Les tests réalisés avec la fonction t.test confirment les conclusions précédentes : moyenne estimée proche de 7.846, intervalles de confiance conformes, et p-valeur de 0.2099 indiquant un échec à rejeter H_0 .

6. Visualisation de la statistique de test

La densité de la loi de Student à 99 degrés de liberté montre clairement la position de la statistique de test observée (en bleu), bien à l'intérieur des quantiles critiques (en rouge), ce qui visuellement confirme la décision de ne pas rejeter l'hypothèse nulle.

Conclusion partielle de la partie 2

L'analyse de l'échantillon de taille 100 montre que la moyenne empirique de V_{mag} est estimée avec une précision plus grande qu'avec l'échantillon de taille 30, comme l'attestent les intervalles de confiance plus étroits à 95 % et 99 %. On rappelle que l'intervalle à 99 % est plus large que celui à 95 %, car un niveau de confiance plus élevé signifie un risque d'erreur plus faible, mais un intervalle plus étendu. Les tests statistiques à ces deux niveaux de risque, basés sur la statistique t et la p-valeur, indiquent que nous **n'avons pas de raison de rejeter** l'hypothèse nulle $\mu = 8$. La représentation graphique de la densité de la loi t sous H_0 illustre clairement la position de la statistique de test et des bornes critiques, ce qui confirme visuellement la décision du test. Ainsi, la taille d'échantillon plus importante renforce la puissance du test et la fiabilité de l'estimation.

Conclusion générale

L'étude statistique menée sur deux échantillons de tailles différentes (30 et 100) a permis d'estimer la moyenne de la magnitude apparente d'une étoile à l'aide d'intervalles de confiance à 95 % et 99 %, puis de tester l'hypothèse $\mu = 8$ à l'aide de tests t .

Dans les deux cas, les résultats indiquent que la valeur hypothétique $\mu = 8$ est compatible avec les données observées : l'hypothèse nulle n'est pas rejetée, que le risque d'erreur soit de 5 % ou de 1 %. Toutefois, l'échantillon de taille 100 offre une estimation plus précise, avec des intervalles de confiance plus resserrés et une meilleure stabilité des résultats.

L'utilisation conjointe des intervalles de confiance, du test t et de la visualisation graphique a permis de valider rigoureusement les conclusions, illustrant le rôle central de la taille d'échantillon dans la qualité des analyses statistiques.

Annexe code R :

```
# Compte Rendu : SAE Estimation par échantillonnage
# CHEN Enzo, DAI Michael, MA Hugo
# BUT 1 SD Groupe 11

rm(list = ls())

# ENVIRONNEMENT ----

# setwd("C:/Users/michael.dai/OneDrive - Université de
Paris/SAE/Estimation par échantillonnage Avr25/Travail SAE")
# setwd("C:/Users/micha/OneDrive - Université de Paris/SAE/Estimation par
échantillonnage Avr25/Travail SAE")

require(tidyverse)
require(matrixStats)

# IMPORT DES DONNEES ----

## Import des fichiers ----

Vmag30 = read.table("vmag30_1.txt",header = TRUE)
View(Vmag30)

Vmag100 = read.table("vmag100_1.txt",header = TRUE)
View(Vmag100)

Stars = read.csv("Star39552_balanced.csv")
View(Stars)

muttheo = mean(Stars$Vmag)
muttheo

# ANALYSE DES DONNEES ----

## 1. Echantillon de taille 30 ----

### 1.1 Statistiques descriptives ----

ggplot(data = Vmag30) +
  aes(y = Vmag) +
  labs(title = "Boîte à moustaches de Vmag, échantillon taille 30",
       y = "Vmag = magnitude apparente de l'étoile") +
  geom_boxplot()

boxplot(Vmag30$Vmag,
       main = "Boîte à moustaches de Vmag, échantillon taille 30",
       ylab = "Vmag = magnitude apparente de l'étoile")
```

```
ggplot(data = Vmag30) +
  aes(x = Vmag) +
  labs(title = "Histogramme de Vmag, échantillon taille 30",
        x = "Vmag = magnitude apparente de l'étoile",
        y = "Effectif") +
  geom_histogram(binwidth = 0.5) +
  scale_x_continuous(breaks = seq(3, 12, by = 1)) +
  theme_minimal()
```

```
summary(Vmag30)
sd(Vmag30$Vmag)
var(Vmag30$Vmag)
```

```
### 1.2 Intervalle de confiance ----
```

```
#### 1.2.1 Niveau de risque 95% ----
```

```
Xbar_30 = mean(Vmag30$Vmag)
sigma_30 = sd(Vmag30$Vmag)
alpha = 1 - 0.95
n = 30
qt((1-(alpha/2)),n-1)
```

```
Ecart = qt((1-(alpha/2)),n-1) * sigma_30 / sqrt(n)
```

```
a = Xbar_30 - Ecart
b = Xbar_30 + Ecart
```

```
print(paste("Xbar =",Xbar_30,"IC",100*(1-alpha),"% [",a,"-",b,"]"))
```

```
#### 1.2.2 Niveau de risque 99% ----
```

```
Xbar_30 = mean(Vmag30$Vmag)
sigma_30 = sd(Vmag30$Vmag)
alpha = 1 - 0.99
n = 30
qt((1-(alpha/2)),n-1)
```

```
Ecart = qt((1-(alpha/2)),n-1) * sigma_30 / sqrt(n)
```

```
a = Xbar_30 - Ecart
b = Xbar_30 + Ecart
```

```
print(paste("Xbar =",Xbar_30,"IC",100*(1-alpha),"% [",a,"-",b,"]"))
```

```
### 1.3 Test de comparaison ----
```



```
#### 1.3.1 Niveau de risque 95% ----
```

```
##### 1.3.1.1 Statistique de test ----
```

```
Xbar_30 = mean(Vmag30$Vmag)
sigma_30 = sd(Vmag30$Vmag)
mu0 = 8
alpha = 0.05
n = 30
```

```
t = sqrt(n) * (Xbar_30 - mu0) / sigma_30
t
```

```
##### 1.3.1.2 Quantile du test ----
```

```
qt((1-(alpha/2)),n-1)
```

```
##### 1.3.1.3 p-valeur du test ----
```

```
pval = 2 * (pt(abs(t),n-1,lower.tail = FALSE))
pval
```

```
#### 1.3.2 Niveau de risque 99% ----
```

```
##### 1.3.2.1 Statistique de test ----
```

```
Xbar_30 = mean(Vmag30$Vmag)
sigma_30 = sd(Vmag30$Vmag)
mu0 = 8
alpha = 0.01
n = 30
```

```
t = sqrt(n) * (Xbar_30 - mu0) / sigma_30
t
```

```
##### 1.3.2.2 Quantile du test ----
```

```
qt((1-(alpha/2)),n-1)
```

```
##### 1.3.2.3 p-valeur du test ----
```

```
pval = 2 * (pt(abs(t),n-1,lower.tail = FALSE))
pval
```

```
### 1.4 Test avec les intervalles de confiance ----
```

```
#### 1.4.1 Niveau de risque 95% ----
```

```

mu0 = 8
alpha = 1 - 0.95
n = 30
qt((1-(alpha/2)),n-1)

Ecart = qt((1-(alpha/2)),n-1) * sigma_30 / sqrt(n)

a = Xbar_30 - Ecart
b = Xbar_30 + Ecart

print(paste("Mu0 =",mu0,"IC",100*(1-alpha),"% [",a,"-",b,"]"))

```

1.4.2 Niveau de risque 99% ----

```

mu0 = 8
alpha = 1 - 0.99
n = 30
qt((1-(alpha/2)),n-1)

Ecart = qt((1-(alpha/2)),n-1) * sigma_30 / sqrt(n)

a = Xbar_30 - Ecart
b = Xbar_30 + Ecart

print(paste("Mu0 =",mu0,"IC",100*(1-alpha),"% [",a,"-",b,"]"))

```

1.5 Test avec l'instruction R t.test ----

1.5.1 Niveau de risque 95% ----

```

alpha = 1 - 0.95

t.test(Vmag30,mu=mu0, conf.level=1-alpha)

```

1.5.2 Niveau de risque 99% ----

```

alpha = 1 - 0.99

t.test(Vmag30,mu=mu0, conf.level=1-alpha)

```

1.6 Densité de la loi de la statistique de test sous H0 ----

1.6.1 Niveau de risque 95% ----

```

alpha = 1 - 0.95

curve(dt(x,n-1),col="black",from=-3.5,to=3.5,xlab="graphique alpha=5%")

```

```
abline(v=t,lwd=2,col="blue")#Statistique de Test Observee
abline(v=qt((1-(alpha/2)),n-1),lwd=2,col="red")#Quantile d'ordre 97.5%
represente par une ligne verticale rouge
abline(v=qt((alpha/2),n-1),lwd=2,col="red")#Quantile d'ordre 2.5%
represente par une ligne verticale rouge
```

```
#### 1.6.2 Niveau de risque 99% ----
```

```
alpha = 1 - 0.99
```

```
curve(dt(x,n-1),col="black",from=-3.5,to=3.5,xlab="graphique alpha=1%")
abline(v=t,lwd=2,col="blue")#Statistique de Test Observee
abline(v=qt((1-(alpha/2)),n-1),lwd=2,col="red")#Quantile d'ordre 99.5%
represente par une ligne verticale rouge
abline(v=qt((alpha/2),n-1),lwd=2,col="red")#Quantile d'ordre 0.5%
represente par une ligne verticale rouge
```

```
#####
## 2. Echantillon taille 100 ----
```

```
### 2.1 Statistiques descriptives ----
```

```
ggplot(data = Vmag100) +
  aes(y = Vmag) +
  labs(title = "Boîte à moustaches de Vmag, échantillon taille 100",
        y = "Vmag = magnitude apparente de l'étoile") +
  geom_boxplot()
```

```
boxplot(Vmag100$Vmag,
        main = "Boîte à moustaches de Vmag, échantillon taille 100",
        ylab = "Vmag = magnitude apparente de l'étoile")
```

```
ggplot(data = Vmag100) +
  aes(x = Vmag) +
  labs(title = "Histogramme de Vmag, échantillon taille 100",
        x = "Vmag = magnitude apparente de l'étoile",
        y = "Effectif") +
  geom_histogram(binwidth = 0.5) +
  scale_x_continuous(breaks = seq(3, 12, by = 1)) +
  theme_minimal()
```

```
summary(Vmag100)
sd(Vmag100$Vmag)
var(Vmag100$Vmag)
```

```
### 2.2 Intervalle de confiance ----
```

```
#### 2.2.1 Niveau de risque 95% ----
```

```
Xbar_100 = mean(Vmag100$Vmag)
sigma_100 = sd(Vmag100$Vmag)
alpha = 1 - 0.95
n = 100
qt((1-(alpha/2)),n-1)
```

```
Ecart = qt((1-(alpha/2)),n-1) * sigma_100 / sqrt(n)
```

```
a = Xbar_100 - Ecart
b = Xbar_100 + Ecart
```

```
print(paste("Xbar =",Xbar_100,"IC",100*(1-alpha),"% [",a,"-",b,"]"))
```

```
#### 2.2.2 Niveau de risque 99% ----
```

```
Xbar_100 = mean(Vmag100$Vmag)
sigma_100 = sd(Vmag100$Vmag)
alpha = 1 - 0.99
n = 100
qt((1-(alpha/2)),n-1)
```

```
Ecart = qt((1-(alpha/2)),n-1) * sigma_100 / sqrt(n)
```

```
a = Xbar_100 - Ecart
b = Xbar_100 + Ecart
```

```
print(paste("Xbar =",Xbar_100,"IC",100*(1-alpha),"% [",a,"-",b,"]"))
```

```
### 2.3 Test de comparaison ----
```

```
#### 2.3.1 Niveau de risque 95% ----
```

```
##### 2.3.1.1 Statistique de test ----
```

```
Xbar_100 = mean(Vmag100$Vmag)
sigma_100 = sd(Vmag100$Vmag)
mu0 = 8
alpha = 0.05
n = 100
```

```
t = sqrt(n) * (Xbar_100 - mu0) / sigma_100
t
```

```
##### 2.3.1.2 Quantile du test ----
```

```
qt((1-(alpha/2)),n-1)
```

```
##### 2.3.1.3 p-valeur du test ----
```

```
pval = 2 * (pt(abs(t),n-1,lower.tail = FALSE))  
pval
```

```
#### 2.3.2 Niveau de risque 99% ----
```

```
##### 2.3.2.1 Statistique de test ----
```

```
Xbar_100 = mean(Vmag100$Vmag)  
sigma_100 = sd(Vmag100$Vmag)  
mu0 = 8  
alpha = 0.01  
n = 100
```

```
t = sqrt(n) * (Xbar_100 - mu0) / sigma_100  
t
```

```
##### 2.3.2.2 Quantile du test ----
```

```
qt((1-(alpha/2)),n-1)
```

```
##### 2.3.2.3 p-valeur du test ----
```

```
pval = 2 * (pt(abs(t),n-1,lower.tail = FALSE))  
pval
```

```
### 2.4 Test avec les intervalles de confiance ----
```

```
#### 2.4.1 Niveau de risque 95% ----
```

```
mu0 = 8  
alpha = 1 - 0.95  
n = 100  
qt((1-(alpha/2)),n-1)
```

```
Ecart = qt((1-(alpha/2)),n-1) * sigma_100 / sqrt(n)
```

```
a = Xbar_100 - Ecart  
b = Xbar_100 + Ecart
```

```
print(paste("Mu0 =",mu0,"IC",100*(1-alpha),"% [",a,"-",b,"]"))
```

```
#### 2.4.2 Niveau de risque 99% ----
```

```

mu0 = 8
alpha = 1 - 0.99
n = 100
qt((1-(alpha/2)),n-1)

Ecart = qt((1-(alpha/2)),n-1) * sigma_100 / sqrt(n)

a = Xbar_100 - Ecart
b = Xbar_100 + Ecart

print(paste("Mu0 =",mu0,"IC",100*(1-alpha),"% [",a,"-",b,"]"))

```

2.5 Test avec l'instruction R t.test ----

2.5.1 Niveau de risque 95% ----

```

alpha = 1 - 0.95

t.test(Vmag100,mu=mu0, conf.level=1-alpha)

```

2.5.2 Niveau de risque 99% ----

```

alpha = 1 - 0.99

t.test(Vmag100,mu=mu0, conf.level=1-alpha)

```

2.6 Densité de la loi de la statistique de test sous H0 ----

2.6.1 Niveau de risque 95% ----

```

alpha = 1 - 0.95

curve(dt(x,n-1),col="black",from=-3.5,to=3.5,xlab="graphique alpha=5%")
abline(v=t,lwd=2,col="blue")#Statistique de Test Observee
abline(v=qt((1-(alpha/2)),n-1),lwd=2,col="red")#Quantile d'ordre 97.5%
represente par une ligne verticale rouge
abline(v=qt((alpha/2),n-1),lwd=2,col="red")#Quantile d'ordre 2.5%
represente par une ligne verticale rouge

```

2.6.2 Niveau de risque 99% ----

```

alpha = 1 - 0.99
curve(dt(x,n-1),col="black",from=-3.5,to=3.5,xlab="graphique alpha=1%")
abline(v=t,lwd=2,col="blue")#Statistique de Test Observee
abline(v=qt((1-(alpha/2)),n-1),lwd=2,col="red")#Quantile d'ordre 99.5%
represente par une ligne verticale rouge
abline(v=qt((alpha/2),n-1),lwd=2,col="red")#Quantile d'ordre 0.5%
represente par une ligne verticale rouge

```