

RAPPORT SAE Séries Temporelles

Qualité de l'air dans les stations de RER parisiennes

Titulaire : M. GOMEZ GARCIA

Groupe/Binôme : 5

BUT 2 SD EMS FI

Enzo CHEN

Michael DAI



SOMMAIRE :

I. Introduction	3
II. Données et traitement des NA	4
1. Première stratégie sans succès	4
2. Solution retenue : agrégation journalière	5
III. Évolution de la série d'entraînement	6
A. Tendance.....	6
1. Descriptions des courbes de tendances	6
2. Interprétations	7
B. Saisonnalité.....	7
1. Saison annuelle du CO ₂ à Châtelet : La série de saisonnalité	7
2. Série désaisonnalisée (CVS) du CO ₂	8
C. Résidus	9
D. Résumé	10
IV. Prévisions	11
A) Modèle ARIMA/SARMA	11
1) Méthode AUTO_ARIMA : échec de modélisation.....	11
2) Modèle SARMA : Construire le modèle manuellement	11
B. Modèle HOLT-WINTERS	12
C. Modèle polynôme de degré 2.....	12
D. Comparaison des trois méthodes.....	13
V. Conclusion.....	14
VI. Summary (English)	15
VII. Annexes.....	16

I. Introduction

La qualité de l'air dans les espaces souterrains constitue un enjeu majeur de santé publique, en particulier dans les grandes agglomérations où les réseaux de transport collectif sont fortement sollicités. Depuis 1997, la RATP surveille en continu plusieurs paramètres de pollution au sein de son réseau métropolitain et ferroviaire, notamment la température, l'humidité, les oxydes d'azote (NO, NO₂), le dioxyde de carbone (CO₂) et les particules fines (PM₁₀). Cinq stations parisiennes sont équipées de dispositifs de mesure automatisés dont les enregistrements permettent d'étudier de manière détaillée l'évolution de la qualité de l'air en milieu souterrain.

Dans le cadre de notre projet, la RATP nous a confié plusieurs missions accompagnées de deux jeux de données, fournis sous forme de fichiers CSV, portant sur la pollution mesurée à la station Châtelet.

Le premier fichier, *chatelet_2013_2020.csv*, couvre la période de 2013 à 2020 et contient 70 076 observations. Le second, *chatelet_2021_2025.csv*, couvre la période du 1er janvier 2021 au 23 janvier 2025 et comprend 41 562 observations.

Chaque fichier contient une variable date/heure (au format *aaaa-mm-jj-hh*) ainsi que plusieurs indicateurs environnementaux : le monoxyde d'azote (NO), mesuré en µg/m³, le dioxyde d'azote (NO₂), mesuré en µg/m³, le dioxyde de carbone (CO₂), mesuré en ppm, les PM10, correspondant à la concentration de particules fines, mesurée en µg/m³, la TEMP, correspondant à la température, mesurée en degrés Celsius (°C), la HUMI, correspondant à l'humidité relative, mesurée en pourcentage (%).

La première mission confiée à notre équipe de statisticiens consiste à étudier l'évolution de la concentration en dioxyde de carbone (CO₂) à la station Châtelet à partir du 22 novembre 2018, date retenue en raison de la présence de nombreux blocs de données manquantes avant cette période.

L'objectif final est de produire des prédictions de la concentration en CO₂ durant la période d'interruption de la surveillance de la qualité de l'air, qui s'étend du 23 janvier 2025 au 31 décembre 2025.

L'enjeu principal de cette mission est de répondre à la problématique suivante : comment prédire l'évolution de la concentration en CO₂ à la station Châtelet durant l'interruption de la surveillance de la qualité de l'air en 2025 ?

Cette mission vise ainsi à proposer une analyse complète de l'évolution temporelle du CO₂, exprimé en ppm, en mettant en évidence les trois composantes fondamentales d'une série temporelle (tendance, saisonnalité et résidu). Cette analyse servira de base à la construction de modèles de prévision fiables, destinés à estimer l'évolution future de la qualité de l'air pendant l'interruption des mesures liée aux travaux réalisés dans la station.

II. Données et traitement des NA

Les données utilisées proviennent de l'extraction des deux fichiers CSV fournis par la RATP, couvrant la période du 22 novembre 2018 au 23 janvier 2025. Seules les variables DATE/HEURE et CO₂ ont été conservées. Le jeu de données contient 50 418 observations horaires avec horodatage (DATE_HEURE, POSIXct) et valeurs de CO₂.

Deux sous-séries ont été extraites. La première, dite série d'entraînement, couvre la période du 22 novembre 2018 au 31 août 2024 et sert à la construction des modèles de prévision. La seconde, dite série de test, couvre la période du 31 août 2024 au 23 janvier 2025 et permet d'évaluer les performances des modèles jusqu'au début de l'interruption des mesures.

Le travail de préparation des données a été réalisé uniquement sur la série d'entraînement car c'est cette série ne doit pas comporter de NA et doit être la plus cohérente possible afin de ressortir la meilleure analyse de ses trois composantes (tendance, saisonnalité et résidus), pour finalement obtenir une prévision la plus précise possible. Cette série comporte 5 569 valeurs manquantes sur 50 418 observations. La phase d'imputation a été longue : une première méthode complexe n'a pas donné de bons résultats, et nous avons dû adopter une stratégie plus adaptée. Nous présentons néanmoins cette première approche pour illustrer notre démarche et les difficultés rencontrées.


1. Première stratégie sans succès

La première étape consistait à localiser les valeurs manquantes dans le jeu de données. Nous avons relevé 270 blocs de valeurs manquantes consécutives (« gaps »), dont la taille varie de 1 à 1800 heures. Si de nombreux gaps sont très courts (moins de 100 observations), certains sont extrêmement longs, nécessitant des méthodes différentes selon leur taille.

Pour les gaps de moins de 100 observations, nous avons utilisé une interpolation linéaire. Sur de courtes périodes, la concentration en CO₂ reste relativement stable, et cette méthode permet de conserver la cohérence locale avec les valeurs observées.

Après avoir imputé les gaps courts, il restait les gaps supérieurs à 100 observations. Pour les imputer, nous avons envisagé l'utilisation d'un modèle de prévision Holt-Winters. La procédure suivie était la suivante : commencer par le gap le plus récent, utiliser toutes les données observées situées avant ce gap comme série d'entraînement, produire une prévision couvrant exactement la taille du gap, imputer ces valeurs dans la série, puis passer au gap suivant situé immédiatement à droite et répéter le processus. Cette approche visait à reconstituer progressivement la série en partant du gap le plus récent, en utilisant à chaque étape les données les plus complètes.

Imputation NA via Holt-Winters



Résultats

Les prédictions pour les gaps longs se sont révélées peu fiables. Elles présentaient des niveaux irréalistes, des tendances incohérentes avec une augmentation importante de tendance pour les gaps les plus longs. Selon nous, c'est à cause de la longueur importante de certains gaps et la forte variabilité des données qui ont limité l'efficacité de cette méthode.


2. Solution retenue : agrégation journalière

La reconstruction complète de la série horaire avec la première stratégie n'étant pas fiable, nous avons opté pour une autre approche. Pour simplifier l'imputation, la série horaire a été convertie en série journalière en calculant la moyenne des valeurs horaires par jour. Cette méthode présente deux avantages : elle réduit la sensibilité aux données manquantes (seules les journées entièrement vides posent problème) et elle conserve une structure suffisante pour analyser tendances et saisonnalités.

Après cette agrégation, quelques jours sans mesure subsistaient encore, générant des valeurs manquantes (NA), ce sont les jours qui n'ont aucune données horaires dans le jeu de données initiale. Par ailleurs nous avons remarqué que six dates entre le 21 et le 27 mars 2021 étaient absentes dans le jeu de données de base alors nous les avons ajoutées avec des NA, qui seront imputés lors de l'étape suivante.

Imputation finale : moyenne inter-annuelle

Pour imputer les derniers NA journaliers, chaque valeur manquante a été remplacée par la moyenne du même jour dans les autres années. Par exemple, le 21 mars 2021 est remplacé par la moyenne des 21 mars 2019, 2020, 2021, 2023, et 2024. Cette méthode exploite la régularité saisonnière annuelle et permet d'obtenir un jeu de données complet et cohérent, prêt pour l'analyse et la prévision. A travers le graphique ci-dessous, on voit que cette nouvelle série est beaucoup plus cohérente que celle trouvée dans la première stratégie de traitement de NA.



Limites

Néanmoins, cette approche présente deux limites principales : la perte d'information horaire, car le lissage journalier masque les variations intrajournalières. La deuxième limite est que cette imputation de moyenne inter-annuelle suppose l'hypothèse de stabilité saisonnière, qui part du principe que le niveau de CO₂ d'un jour est comparable d'une année sur l'autre. Malgré ces limites, cette stratégie constitue un compromis fiable et stable entre réalisme et absence de distorsion due à des imputations incertaines.


III. Évolution de la série d'entraînement

Pour étudier l'évolution de la série d'entraînement en vue de la prévision, nous analyserons ses trois composantes principales : la tendance, la saisonnalité et le résidu.

A. Tendance

1. Descriptions des courbes de tendances

La première étape consiste à examiner la composante tendancielle de la série.




La courbe journalière (en bleue) des concentrations de CO₂ à Châtelet montre un niveau général compris entre environ 450 et 600 ppm, avec quelques pics supérieurs à 650 ppm et une moyenne visuelle autour de 520–550 ppm, ce qui est supérieur au fond atmosphérique (~420 ppm). La variabilité jour à jour est forte, reflétant le trafic, les activités humaines et les conditions météorologiques. Lorsqu'on regarde de plus près, le cycle saisonnier est visible avec des maxima en hiver et des minima en été, mais bruité. Sur le long terme, aucune tendance linéaire nette n'est détectée, avec une stabilité globale ponctuée de variations annuelles et d'épisodes particuliers.

La courbe hebdomadaire (en rouge) lisse la série journalière, avec des valeurs autour de 480–580 ppm et des pics extrêmes atténués. La variabilité est moins forte et structurée sur plusieurs semaines. Le cycle saisonnier apparaît plus clairement, avec maxima en hiver et minima en été. L'évolution interannuelle montre un creux en 2020, une remontée progressive de 2021 à 2023, puis une stabilisation relative. La tendance est ainsi plus visible sur cette courbe hebdomadaire.

La courbe mensuelle (en violet) est très lisse, avec des valeurs comprises entre 480 et 570 ppm en moyenne et les pics extrêmes supprimés. Le cycle saisonnier est régulier et stable, avec une amplitude annuelle d'environ 50–70 ppm. L'évolution interannuelle reflète le creux de 2020, suivi d'une remontée progressive à partir de 2021.

La courbe annuelle (en vert) est très lisse, avec des valeurs comprises entre 490 et 560 ppm et aucune variation saisonnière visible. La tendance interannuelle est stable de 2019 à 2020, puis baisse légèrement entre 2020 et 2021, avant une nette remontée entre 2022 et 2024 et une stabilisation partielle en 2025. Cette courbe permet de visualiser la tendance de fond en éliminant la variabilité locale et saisonnière.



La moyenne mobile d'ordre 365 lisse la série sur un an et ressemble à la courbe annuelle tout en restant plus réactive aux variations interannuelles. Elle est calculée du 24 mai 2019 au 1er mars 2024, en raison du filtre centré sur 365 jours, et commence 183 jours après le début de la série d'entraînement pour s'achever 182 jours avant la fin. L'évolution observée montre une baisse de 544 ppm à 486,6 ppm entre mai 2019 et novembre 2020, suivie d'une reprise progressive jusqu'à 546,5 ppm en janvier 2024. Cette approche visualise la tendance à long terme similaire à la courbe de régression annuelle.

2. Interprétations

À la station Châtelet, les concentrations de CO₂ présentent des niveaux élevés et une forte variabilité quotidienne, reflet des émissions locales liées au trafic, au chauffage et aux activités humaines. Cette variabilité masque les tendances à long terme à cause du bruit, nécessitant l'usage de moyennes hebdomadaires, mensuelles ou annuelles.

Le cycle saisonnier est net, avec des maxima en hiver (chauffage, atmosphère stable, végétation inactive...) et des minima en été (photosynthèse active, meilleure dispersion de l'air, non utilisation de chauffage...). Ce cycle est observable à l'échelle journalière, hebdomadaire et mensuelle, mais disparaît sur l'échelle annuelle fortement atténué par la courbe de régression de moyenne annuelle et de la moyenne mobile d'ordre 365.


La courbe annuelle et la moyenne mobile sur 365 jours montrent la tendance de fond : une baisse du CO₂ entre mai 2019 et novembre 2020, suivie d'une reprise progressive jusqu'en janvier 2024, traduisant l'impact d'événements ponctuels comme les confinements (COVID 19) ou travaux dans la station.

L'analyse à différentes échelles temporelles permet de distinguer la variabilité locale (journalière), la saisonnalité (mensuelle) et la tendance interannuelle (annuelle et MM365). Ainsi, le CO₂ à Châtelet est marqué par une forte influence des sources locales et une saisonnalité annuelle bien identifiable, tandis que les moyennes et la MM365 révèlent la tendance de fond.

B. Saisonnalité

1. Saison annuelle du CO₂ à Châtelet : La série de saisonnalité

Les coefficients saisonniers du CO₂ à Châtelet varient d'environ -40 à +40 ppm, soit une amplitude de près de 80 ppm, ce qui traduit une saisonnalité très marquée liée aux émissions locales, à la végétation et à la dynamique atmosphérique. La structure annuelle est claire, avec des valeurs positives en hiver et négatives en été, et des transitions progressives au printemps et à l'automne.



Au cours de l'hiver (jours 1–80 et 330–365), les coefficients sont majoritairement positifs (+10 à +40 ppm), ce qui indique des concentrations de CO₂ supérieures à la moyenne annuelle. Cette situation s'explique principalement par une forte fréquentation humaine et par le fonctionnement des systèmes de ventilation. En hiver, les passagers portent davantage de vêtements, ce qui augmente la chaleur corporelle dégagée. Afin de limiter les pertes de chaleur et de réduire la consommation énergétique, la ventilation mécanique est souvent réglée pour restreindre l'entrée d'air froid extérieur. Le renouvellement de l'air est donc plus faible qu'en été, favorisant l'accumulation du CO₂.

Au printemps (jours 80–150), il s'agit d'une période de transition. Les coefficients alternent entre valeurs positives et négatives. L'augmentation progressive des températures entraîne une activation plus fréquente des systèmes de ventilation, permettant d'évacuer la chaleur et de renouveler davantage l'air. Par conséquent, les concentrations de CO₂ commencent à diminuer.


L'été (jours 150–260) se caractérise par des coefficients négatifs (–40 à –50 ppm), correspondant aux concentrations de CO₂ les plus faibles. Les températures élevées conduisent les systèmes de ventilation mécanique à fonctionner à plein régime pour évacuer la chaleur, sans contrainte de conservation thermique. De plus, la fréquentation de la station peut être réduite pendant les vacances estivales, ce qui diminue la fréquentation humaine et donc les émissions de CO₂.

Enfin, l'automne (jours 260–330) est marqué par une remontée progressive des coefficients vers des valeurs positives. Cette évolution est liée à la baisse des températures, à la fin de la période de vacances et à l'augmentation du trafic de transport. Les systèmes de ventilation deviennent progressivement moins actifs afin de conserver la chaleur, marquant ainsi la transition vers l'hiver.

La saisonnalité met en évidence le cycle annuel moyen du CO₂, son amplitude saisonnière importante ($\approx \pm 50$ ppm), le rôle dominant des processus saisonniers et la cohérence interannuelle. En revanche, elle ne reflète pas les événements ponctuels, les différences entre années ni les tendances long terme, qui sont contenues dans la tendance et le résidu.

Par conséquent, les concentrations de CO₂ varient selon les saisons en lien avec la fréquentation humaine et le fonctionnement des systèmes de ventilation : élevées en hiver, diminuant au printemps, les plus basses en été, puis remontant en automne. Ces variations reflètent l'adaptation de la ventilation à la température et au trafic, ainsi que l'effet des vacances et de la conservation de chaleur.

2. Série désaisonnalisée (CVS) du CO₂



La série désaisonnalisée (CVS) du CO₂ correspond à la concentration quotidienne sans la composante saisonnière annuelle. Elle permet de mettre en évidence la tendance de fond et la variabilité journalière non saisonnière, liés à la fréquentation, à la ventilation ou à des événements ponctuels.

Les valeurs de la CVS se situent principalement entre 480 et 580 ppm, mais restent très volatiles. On observe des pics supérieurs à 600 ppm et des creux autour de 440–460 ppm. Cette variabilité reflète l'influence combinée des activités humaines et des aspects techniques propres à la station.


Sur le plan temporel, la série montre des niveaux élevés entre 2018 et début 2020 (≈540–570 ppm) avec une forte variabilité. Au printemps 2020, une chute majeure (≈470–500 ppm) est visible, liée aux confinements durant la pandémie et à la baisse du trafic. Entre 2021 et 2022, la reprise progressive conduit les niveaux à environ 520–550 ppm, avec une variabilité accrue. Enfin, de 2023 à l'été 2024, la série se stabilise, avec des pics fréquents au-dessus de 600 ppm et des niveaux moyens légèrement inférieurs à ceux de 2019.

Même après désaisonnalisation, la série conserve de fortes fluctuations dues à plusieurs facteurs : la fréquentation humaine (heures de pointe, événements, grèves, vacances), la ventilation et les aspects techniques (réglages, maintenance, travaux), les événements météorologiques (canicules, inversions thermiques, pollution), les effets locaux et micro-événements (flux de voyageurs, ouverture/fermeture de portes, mouvements des rames) et les chocs structurels tels que la pandémie de 2020 ou les changements de fréquentation. La désaisonnalisation ne supprime que les cycles annuels réguliers, laissant visibles toutes les variations irrégulières ou ponctuelles, expliquant la forte volatilité de la CVS.

En conclusion, la CVS révèle la dynamique réelle et quotidienne du site, mettant en évidence les ruptures structurelles, les fluctuations locales et l'impact des événements et de la ventilation. Elle constitue un outil essentiel pour analyser les effets non saisonniers sur la qualité de l'air, tout en retirant le "masque" de la saisonnalité annuelle.

C. Résidus

Le boxplot des résidus du CO₂ à Châtelet montre que la distribution est centrée autour de zéro, avec une médiane d'environ –0,57 ppm et une moyenne proche de –0,08 ppm, ce qui indique l'absence de biais systématique. Les quartiles s'étendent d'environ –17,7 ppm à +17,5 ppm, signifiant que la moitié des jours présentent des résidus contenus dans ±18 ppm. L'amplitude totale varie de –123 à +115 ppm, révélant la présence d'événements ponctuels extrêmes. Au total, 40 valeurs statistiquement exceptionnelles ont été identifiées (Les points en dehors des moustaches), réparties entre résidus très négatifs (–70 à –123 ppm) et très positifs (+70 à +115 ppm).



En identifiant les 40 valeurs extrêmes et leurs dates, on peut réaliser une analyse temporelle.


L'analyse temporelle des résidus du CO₂ à Châtelet montre que la variabilité et les valeurs extrêmes sont concentrées sur des périodes spécifiques. En 2019, plusieurs résidus négatifs importants apparaissent fin avril (jours 2019.397 à 2019.474, -71 à -72 ppm), reflétant des baisses inhabituelles, tandis que des résidus positifs apparaissent fin septembre (2019.775 à 2019.890, +70 à +82 ppm), correspondant à des affluences exceptionnelles ou des perturbations ponctuelles.

En 2020, l'impact du COVID se traduit par des creux très profonds: des résidus fortement négatifs surviennent en début de 2020 (-88 à -129 ppm), illustrant le début du confinement, et une baisse considérable du trafic de transport. Entre 2021 et 2022, la reprise du trafic reste irrégulière, avec des extrêmes négatifs début 2021 (-72 à -87 ppm) et début 2022 (-71 à -89 ppm), et des pics positifs en 2021 et 2022 (+73 à +96 ppm).

Enfin, en 2023, des extrêmes particulièrement élevés sont observés : un résidu positif atteint +135 ppm à la fin de l'année (2023.934), témoignant de saturations ponctuelles ou d'une ventilation insuffisante. Cette analyse montre que les valeurs extrêmes ne sont pas uniformément réparties dans le temps mais se concentrent lors de périodes de perturbation, de chocs structurels ou de changements dans la fréquentation et la ventilation.

En conclusion, la majorité des jours suit correctement le modèle de tendance et de saisonnalité annuelle, tandis que les 44 valeurs extrêmes reflètent la dynamique réelle et chaotique de la station, influencée par la fréquentation humaine, les perturbations du réseau, la ventilation, la météo et les ruptures structurelles telles que le COVID.

D. Résumé



En résumé à travers ce graphique sur la décomposition de cette série d'entraînement on retrouve :

- La courbe de tendance (trend) correspond à la moyenne mobile sur 365 jours. Elle met en évidence l'évolution de fond du CO₂ à Châtelet, avec une baisse entre 2019 et 2020 suivie d'une remontée progressive jusqu'en 2024, permettant d'identifier l'impact d'événements ponctuels comme les confinements ou les travaux.
- La courbe de saisonnalité montre un cycle annuel du CO₂ lié aux saisons, reflétant les variations de température ainsi que les activités humaines.
- La courbe des résidus (random) montre que la plupart des observations sont bien expliquées par la tendance et la saisonnalité, tandis que les valeurs extrêmes reflètent la variabilité réelle de la station, liée à l'activité humaine, à la météo, à la ventilation et à des événements majeurs comme le COVID.

IV. Prévisions


Dans notre jeu de données complet (22 novembre 2018 – 10 novembre 2025), l'enregistrement du CO₂ (ppm) s'interrompt à partir du 23 janvier 2025 en raison des travaux dans la station de métro Châtelet. Pour estimer au mieux cette période manquante, notre équipe utilise trois méthodes de modélisation de séries temporelles.

Les trois modèles sont entraînés sur la période du 22 novembre 2018 au 31 août 2024 (la série d'entraînement), ce qui permet de générer des prévisions du 1er septembre 2024 au 31 décembre 2025. Les données observées entre le 1er septembre 2024 et le 23 janvier 2025 servent de série de test pour évaluer la précision des modèles avant de projeter sur la période entièrement manquante. C'est pourquoi la série d'entraînement s'arrête au 31 août 2024.

A) Modèle ARIMA/SARMA


1) Méthode AUTO_ARIMA : échec de modélisation

Le premier modèle que nous avons utilisé est le modèle ARIMA, qui est le plus complexe. Nous avons d'abord essayé la fonction `auto_arma` disponible dans R, mais elle n'a pas donné de bons résultats pour notre série temporelle. Les prévisions obtenues semblaient peu réalistes : la trajectoire prédite était très lissée et ne reflétait presque aucune fluctuation, contrairement aux variations marquées observées dans les données réelles. Auto_arma nous a ainsi fourni un modèle ARIMA, un modèle qui n'a pas capté la saisonnalité.



2) Modèle SARMA : Construire le modèle manuellement

Comme le modèle produit par `auto_arma` semblait irréaliste, nous avons construit le modèle manuellement. Cela nous donne ce graphique (modèle SARMA = ARIMA + Saisonnalité), qui est beaucoup plus réaliste :




À court terme, début 2025, la prévision SARMA débute autour de 510–530 ppm. Les premières valeurs prévues s'inscrivent dans la variabilité récente du CO₂ mesuré à la station de Châtelet. À moyen terme, sur l'ensemble de l'année 2025, la prévision met en évidence des oscillations saisonnières marquées, avec des valeurs généralement comprises entre environ 480 et 600 ppm, ponctuellement plus élevées lors de certains

pics. Le niveau moyen reste relativement stable, sans tendance nette à la hausse ou à la baisse. La présence de fluctuations parfois importantes traduit la capacité du modèle à reproduire la variabilité de court terme, mais aussi sa sensibilité aux schémas historiques.

En conclusion, le modèle SARMA propose une prévision cohérente avec l'historique, caractérisée par une saisonnalité persistante et un niveau moyen globalement stable, contrairement au modèle d'auto_arima où la prévision semble peu réaliste : la trajectoire, trop lissée, ne reflète pas les fluctuations marquées des données réelles.

B. Modèle HOLT-WINTERS

Le deuxième modèle utilisé est Holt-Winters. Contrairement au modèle ARIMA, la prévision Holt-Winters (courbe orange) conserve les oscillations saisonnières régulières, avec une amplitude similaire à celle observée avant l'interruption des mesures.




À court terme, fin 2024, la prévision démarre autour de 510–520 ppm, prolongeant le comportement récent de la série sans rupture. À moyen terme, en 2025, elle montre des oscillations régulières entre 470 et 570 ppm, accompagnées d'une légère tendance à la baisse du niveau moyen. Cette méthode suppose que la saisonnalité et les mécanismes influençant le CO₂ restent stables malgré les travaux à la station. Par conséquent, la prévision est plausible mais ne reflète pas nécessairement les impacts réels des travaux sur la qualité de l'air.

En conclusion, le modèle Holt-Winters conserve une forte saisonnalité avec une légère baisse du niveau moyen, mais il repose sur l'hypothèse que les comportements passés restent inchangés.

C. Modèle polynôme de degré 2

Le troisième modèle utilisé est un modèle polynomial de degré 2. Le choix de ce degré repose sur la modélisation polynomiale de la série désaisonnalisée, évaluée à l'aide du critère AIC. Le degré 2 présente l'AIC le plus faible (20902,61), ex æquo avec les degrés 3 et 4. En cas d'égalité, nous retenons le modèle le moins complexe. La composante saisonnière est ensuite réintroduite au modèle polynomial de degré 2, ce qui conduit au graphique présenté ci-dessous.



Le graphique présente trois courbes distinctes. La courbe orange montre la prévision polynomiale.

À court terme, fin 2024, la prévision démarre autour de 550–560 ppm, assurant une continuité avec la modélisation. À moyen terme, en 2025, elle présente une tendance fortement croissante, avec des concentrations atteignant environ 600 ppm, conséquence de la courbure positive du polynôme.


Cette approche repose sur l’hypothèse que la tendance passée se poursuit malgré les travaux à la station.

En conclusion, la méthode polynomiale suggère une hausse continue et marquée du CO₂, avec la saisonnalité conservée. Elle est utile pour lisser la série et décrire la tendance passée, mais elle est moins robuste pour la prévision dans un contexte réel.

D. Comparaison des trois méthodes

Les données d’entraînement utilisées pour cette évaluation couvrent la période du 22 novembre 2018 au 31 août 2024, tandis que les données de test s’étendent du 1er septembre 2024 au 23 janvier 2025. L’indicateur choisi pour comparer les méthodes est l’Erreur Quadratique Moyenne (EQM), où une valeur plus faible correspond à une meilleure qualité de prévision.

Les résultats montrent que la méthode polynomiale de degré 2 obtient l’EQM la plus faible (1 780), suivie de de SARMA à 3248.685 (À noter que l’EQM du modèle auto_arima est de 5237) et de Holt-Winters (3 953). La méthode polynomiale se distingue par sa précision sur le court terme, reproduisant fidèlement le niveau moyen et la tendance récente de la série. Holt-Winters et SARMA capturent tous les deux bien la saisonnalité et l’amplitude des variations, mais leurs précisions sur la tendance globale est moindre.



L’analyse graphique confirme ces observations : la courbe polynomiale (violet) suit de près la série de test (rouge), Holt-Winters (orange) reproduit la saisonnalité avec une dispersion plus marquée cependant elle montre une tendance qui diminue tandis que la série de test montre une tendance qui augmente. Le modèle SARMA (en vert) capture la saisonnalité et la tendance observées, mais la tendance prédite devrait être plus élevée pour mieux correspondre à la réalité (la courbe rouge).

En conclusion, pour cette prévision, la méthode polynomiale est la plus performante avec l’EQM la plus faible égale à 1780.

V. Conclusion

En conclusion, l'analyse de la concentration de CO₂ à la station Châtelet met en évidence une dynamique complexe, influencée à la fois par des facteurs locaux, saisonniers et des événements ponctuels. La série temporelle présente une tendance de fond globalement stable avec une hausse progressive entre 2018 et 2024, une saisonnalité annuelle marquée avec des maxima en hiver et des minima en été, ainsi qu'une composante résiduelle capturant la variabilité réelle liée à la fréquentation, aux conditions techniques et aux événements exceptionnels tels que la crise sanitaire de 2020.

La désaisonnalisation de la série a permis de mettre en évidence les variations non saisonnières et les fluctuations quotidiennes, tandis que l'étude des résidus a confirmé que la majorité des observations se situe dans les limites attendues, les valeurs extrêmes traduisant des situations particulières ponctuelles comme le confinement qui a fortement réduit la concentration de CO₂ en 2020. L'analyse par différentes échelles temporelles – journalière, hebdomadaire, mensuelle, annuelle et moyenne mobile sur 365 jours – a montré que chacune apporte une information spécifique, qu'il s'agisse de suivre la variabilité locale, de visualiser la saisonnalité ou d'identifier la tendance de fond.

Pour la prévision du CO₂ durant la période d'interruption des mesures en 2025, trois méthodes complémentaires ont été comparées. Le modèle polynomial de degré 2 a montré la meilleure précision à court terme, reproduisant fidèlement le niveau moyen et la tendance récente (la série de test). Holt-Winters et SARMA ont bien capté la saisonnalité et l'amplitude des variations, mais avec une moindre exactitude sur les niveaux précis. Cette comparaison met en lumière l'importance de combiner des approches pour appréhender à la fois les tendances, la saisonnalité et la variabilité réelle.

Finalement, l'étude fournit une compréhension approfondie de l'évolution du CO₂ à Châtelet et propose des outils de prévision pour estimer les concentrations pendant l'interruption des mesures, tout en soulignant les limites liées aux changements structurels et aux événements imprévisibles. Elle illustre l'intérêt d'une approche multi-échelle et multi-modèle pour analyser et anticiper la qualité de l'air dans les environnements urbains souterrains.

REPARTITION DES TÂCHES REALISEES :

Notre équipe est composée de deux personnes, Enzo CHEN et Michael DAI. La préparation des données et le traitement des valeurs manquantes (NA) ont été réalisés conjointement par Enzo et Michael. L'analyse de la tendance a été effectuée par Michael, tandis que l'étude de la saisonnalité a été menée par Enzo. La composante résiduelle a été traitée par Michael.

Concernant la prédiction, Michael s'est chargé des modèles ARIMA et Holt-Winters, tandis qu'Enzo a réalisé la modélisation polynomiale de degré 2. Enfin, la comparaison des performances des modèles à l'aide de l'Erreur Quadratique Moyenne (EQM) a été effectuée en collaboration entre Enzo et Michael.

VI. Summary (English)

The analysis of CO₂ concentrations at Châtelet station reveals a complex dynamic shaped by local conditions, seasonal cycles, and occasional events. The time series exhibits a generally stable long-term trend with a gradual increase from 2018 to 2024, a clear annual seasonality with winter peaks and summer troughs, and a residual component reflecting short-term variability linked to passenger traffic, technical conditions, and exceptional events such as the 2020 COVID-19 crisis.

Deseasonalizing the series highlighted structural breaks and daily fluctuations, while the residual analysis confirmed that most values remain within expected ranges, with extremes corresponding to specific events. Multi-scale analysis—daily, weekly, monthly, annual, and 365-day moving averages—showed that each temporal scale offers distinct insights, from local variability to seasonal patterns and long-term trends.

For forecasting CO₂ during the 2025 monitoring gap, three complementary models were evaluated. The degree-2 polynomial model provided the most accurate short-term predictions, closely tracking recent average levels and trends. The Holt-Winters and SARMA models effectively captured seasonality and the amplitude of variations but were less precise for exact levels. This comparison highlights the benefit of combining models to account simultaneously for trends, seasonality, and real-world variability.

Overall, the study offers a detailed understanding of CO₂ dynamics at Châtelet and provides reliable forecasting tools for periods without measurements, while acknowledging limitations related to structural changes and unforeseen events. It underscores the value of a multi-scale, multi-model approach for analyzing and anticipating air quality in urban underground environments.

VII. Annexes


Voici le lien vers le code R :

<https://github.com/Ecn1234/SaeSerieTemporelle>


Voici quelques graphiques complémentaires :

Courbes de régression de tendance :


- **Moyenne journalière**




- **Moyenne hebdomadaire**




- **Moyenne mensuelle**




- Moyenne annuelle




Moyenne Mobile d'ordre 365




Courbe des résidus :




Modèle polynomial de degré 2 ajusté sur la CVS




Graphique ACF lag.max = 20



Graphique ACF lag.max = 400



Graphique PACF lag.max = 20



Graphique PACF lag.max = 400

