

COMPTE RENDU Tests Statistiques

TP 2 : Tests pour l'analyse bivariée

Titulaire : Mme. Muri

BUT 2 SD EMS FI

Enzo CHEN

Michael DAI



Table des matières

I) Introduction	3
II) Analyses descriptive univariées	3
III) Partie méthodologique	3
1. Test de comparaison de la moyenne.....	3
2. un test du Khi-deux d'indépendance	4
3. Test de corrélation de Pearson et Spearman	4
IV) Analyses bivariées.....	4
1. Analyse des différences selon le genre	4
2. Analyse des différences selon le produit	6
3. Analyse des liens entre les variables quantitatives.....	9
V) Conclusion générale	12
VI) Annexes.....	13
1. Analyses univariées.....	13
2. Analyses bivariées.....	14

I) Introduction

Ce compte rendu présente une analyse des profils clients afin de mettre en évidence les similitudes et les différences entre les femmes et les hommes, ainsi qu'entre les clients selon le modèle de tapis de course acheté. L'étude s'appuie sur le jeu de données *Cardio Good Fitness*, issu de la plateforme Kaggle, portant sur des clients ayant acquis l'un des trois modèles de tapis (TM195, TM498 ou TM798).

La base de données est constituée de 180 observations correspondant à des clients ayant acheté un tapis de course. Elle comporte 9 variables décrivant le modèle de tapis acheté (Product : TM195, TM498 ou TM798) ainsi que les caractéristiques sociodémographiques et comportementales des clients : l'âge (Age, en années), le genre (Gender : femme ou homme), le niveau d'études (Education, nombre d'années d'études), le statut matrimonial (MaritalStatus : célibataire ou en couple), la fréquence d'utilisation anticipée du tapis (Usage, nombre moyen d'utilisations hebdomadaires), la condition physique auto-évaluée (Fitness, échelle ordinaire de 1 à 5), le revenu annuel du foyer (Income, en dollars) et la distance hebdomadaire prévue (Miles, en miles).

Ainsi tout au long de l'analyse, nous allons tenter de répondre à la problématique suivante : Quels sont les éléments de différence et de concordance entre les profils des clients femmes et hommes, et entre les différents modèles de produit achetés par les clients ?

II) Analyses descriptive univariées

Dans un premier temps nous allons nous familiariser avec quelques variables de la base via des analyses descriptives univariées. [Cliquer ici pour consulter les tableaux récapitulatifs](#)

Modèle de tapis de course (Product) : Dans la variable *Product*, le modèle TM195 est le plus acheté, avec 80 clients (soit environ 44 % de l'échantillon). Le modèle TM498 concerne 60 clients, tandis que le modèle TM798 est le moins représenté avec 40 clients. Cette répartition suggère une préférence marquée des clients pour le modèle d'entrée de gamme.

Genre (Gender) : On note une majorité d'hommes (104 clients) contre 76 femmes. Les hommes représentent ainsi près de 58 % de l'échantillon. Cette différence indique une surreprésentation masculine parmi les acheteurs de tapis de course dans cette base de données.

Niveau d'études regroupé (Niv) (Variable quantitative Education regroupée en classe) : La catégorie 14–16 années d'études est la plus fréquente (90 individus), suivie de la catégorie 12–14 (63 individus). Les niveaux supérieurs à 16 ans d'études sont moins représentés (27 individus). L'échantillon est donc majoritairement composé de clients ayant un niveau d'études intermédiaire.

Catégorie d'utilisation (Usage_cat) (Variable quantitative Usage regroupée en classe) : On retrouve une majorité d'utilisateurs à faible fréquence d'utilisation (102 clients). Les utilisateurs à usage modéré sont 69, tandis que l'usage élevé reste marginal (9 clients). Cela indique que, même après

III) Partie méthodologique

1. Test de comparaison de la moyenne

Pour étudier le lien entre une variable quantitative et une variable qualitative à deux modalités, un test de comparaison de moyennes est utilisé. Le test de Welch est retenu pour comparer deux grands échantillons (il s'agit ici de notre cas), sans supposer l'égalité des variances. On devrait normalement utiliser le test de la loi normale cependant il n'est pas implémenté sur R, le test de Welch tend vers une loi normale lorsque la taille de l'échantillon augmente c'est pourquoi on choisit comme équivalent le test de Welch dans notre cas avec des grands échantillons (total > 50). L'hypothèse nulle postule l'égalité des moyennes entre les deux groupes, contre une hypothèse alternative de différence. Le test est réalisé à l'aide de la fonction `t.test()` sous R.

2. un test du Khi-deux d'indépendance

Pour analyser le lien entre deux variables qualitatives, un test du Khi-deux d'indépendance est utilisé lorsque les effectifs sont suffisants (total > 50 et effectifs théoriques > 5). L'hypothèse nulle postule l'indépendance des variables, contre une hypothèse alternative de dépendance. En cas de faibles effectifs, le test exact de Fisher est privilégié, éventuellement avec simulation pour les grands tableaux. Les tests sont réalisés sous R avec `chisq.test()` ou `fisher.test()` (ou `fisher.test(table(don$X, don$Y), simulate.p.value = TRUE)` uniquement si la dimension des tableaux est trop importante)

3. Test de corrélation de Pearson et Spearman


L'étude du lien entre deux variables quantitatives repose sur la corrélation. Le test de Pearson est utilisé que dans le cadre linéaire tandis celui de Spearman fonctionne dans une relation monotone, linéaire ou non. L'hypothèse nulle postule un coefficient nul (absence de lien), contre une hypothèse alternative de corrélation non nulle. Les analyses sont réalisées sous R avec `cor.test(X, Y, method = "pearson")` ou `cor.test(X, Y, method = "spearman")` pour la réalisation des tests statistiques associés.

IV) Analyses bivariées

1. Analyse des différences selon le genre

1.1° Revenu annuel selon le genre ([cliquez ici pour consulter son graphique](#))

La boîte à moustaches du revenu annuel selon le genre montre que les hommes ont globalement des revenus plus élevés que les femmes. Le revenu moyen est d'environ 49 829 \$ pour les femmes (droite rouge) et 56 563 \$ pour les hommes (droite bleue), avec des médianes de 47 754 \$ et 52 302 \$ respectivement. La dispersion des revenus est également plus importante chez les hommes.



Afin de tester statistiquement cette différence, un test t de Welch est utilisé, car il permet de comparer les moyennes de deux groupes indépendants sans supposer l'égalité des variances. Les conditions d'application sont jugées acceptables compte tenu des effectifs relativement importants dans chaque groupe (76 femmes et 104 hommes).

Le test retourne une p-valeur de 0,004. Donc en rejetant l'hypothèse nulle d'égalité des moyennes, on a seulement 0,4% de chance de se tromper. Il existe ainsi une différence significative de revenu annuel entre les femmes et les hommes, les hommes ayant en moyenne un revenu plus élevé.

1.2° Âge selon le genre ([cliquez ici pour consulter l'annexe](#))

Les âges médians sont respectivement de 26,5 ans pour les femmes et 26 ans pour les hommes, avec des moyennes quasi identiques. La p-valeur obtenue est de 0,707 très élevée, signifie qu'il est très commun de retrouver ces genres de valeurs s'il n'y a pas de différence entre l'âge médian des hommes et des femmes. On ne rejette donc pas l'hypothèse nulle. Il n'existe pas de différence significative d'âge entre les femmes et les hommes dans cette base de données.

1.3° Distance parcourue prévue selon le genre (Miles) ([cliquez ici pour consulter l'annexe](#))

Les hommes prévoient en moyenne de parcourir des distances plus importantes que les femmes. La moyenne est d'environ 113 miles pour les hommes contre 90 miles pour les femmes, et la médiane est également plus élevée chez

les hommes. Le test t de Welch donne une p-valeur très faible de 0,0025. La différence observée est donc très significative. On conclut que les hommes anticipent une pratique plus intensive du tapis de course que les femmes, en termes de distance parcourue hebdomadaire.

1.4° et 1.4bis° Niveau d'études selon le genre ([cliquez ici pour consulter l'annexe](#))

Les moyennes sont proches (15,4 ans pour les femmes contre 15,7 ans pour les hommes), et les médianes sont identiques, avec une distribution très similaire aussi, écart type similaire. Le test t de Welch retourne une p-valeur de 0,197, plutôt élevée, 19,7% de chance de se tromper en rejetant H_0 . Il n'y a donc pas de différence significative de niveau d'études entre les femmes et les hommes. Le test du Khi-deux d'indépendance est aussi réalisé. Le test fournit une p-valeur de 0,217 très élevée. On ne rejette donc pas l'hypothèse nulle d'indépendance : le niveau d'éducation regroupé ne dépend pas significativement du genre.

1.5° et 1.5bis° Fréquence d'utilisation hebdomadaire prévue selon le genre ([cliquez ici pour consulter l'annexe](#))

À travers le diagramme en barres de la catégorie d'utilisation selon le genre, on observe que les femmes déclarent majoritairement une faible utilisation du tapis (69,7 %), tandis que les hommes sont davantage représentés dans les catégories modérée et élevée. Les usages élevés restent néanmoins très faibles dans les deux groupes. Le test exact de Fisher retourne une p-valeur très faible de 0,009. On conclut donc à l'existence d'un lien significatif entre le genre et la catégorie d'utilisation prévue, les hommes ayant tendance à anticiper une utilisation plus fréquente du tapis.

Si on prend la version quantitative de la fréquence d'utilisation qui garde plus d'information, on constate aussi une fréquence d'utilisation prévue plus élevée chez les hommes. La moyenne est de 3,65 utilisations par semaine pour les hommes contre 3,18 pour les femmes. Le test de Welch confirme cette observation avec une p-valeur de 0,0035, indiquant une différence significative entre les deux groupes. Les hommes déclarent ainsi une utilisation hebdomadaire du tapis de course plus fréquente que les femmes.

1.6° Modèle de tapis acheté selon le genre ([cliquez ici pour consulter l'annexe](#))

Le diagramme en barres croisant le genre et le modèle de tapis acheté met en évidence des différences notables. Les femmes achètent majoritairement le modèle TM195 (52,6 %), tandis que le modèle TM798 est très peu représenté chez elles (9,2 %). À l'inverse, les hommes sont plus nombreux à acheter le modèle TM798 (31,7 %), ce qui suggère une préférence masculine pour les modèles plus haut de gamme.

Pour analyser le lien entre ces deux variables qualitatives, un test du khi-deux d'indépendance est utilisé. Les effectifs théoriques sont tous supérieurs à 5, ce qui valide les conditions d'application du test.

Le test du khi-deux fournit une p-valeur très faible de 0,0016. On rejette donc l'hypothèse d'indépendance : il existe un lien statistiquement significatif entre le genre et le modèle de tapis acheté.

1.7° Condition physique auto-évaluée et genre ([cliquez ici pour consulter l'annexe](#))

L'analyse descriptive met en évidence des différences dans la perception de la condition physique selon le genre. Les hommes déclarent plus fréquemment des niveaux élevés de forme physique (notamment la modalité 5), tandis que les femmes se concentrent davantage autour du niveau 3.

Cependant, certains effectifs théoriques du tableau de contingence sont inférieurs à 5, ce qui rend l'approximation du test du Khi-deux peu fiable. Un test exact de Fisher avec simulation de la p-valeur est donc utilisé. La p-valeur obtenue est faible et égale à 0,0125, ce qui conduit à rejeter l'hypothèse d'indépendance. Il existe ainsi une association statistiquement significative entre le genre et le niveau de condition physique auto-évaluée.

1.8° Statut matrimonial et genre ([cliquez ici pour consulter l'annexe](#))


Enfin, la distribution du statut matrimonial apparaît très similaire entre les femmes et les hommes. Environ 60 % des individus sont en couple dans les deux groupes. Le test du Khi-deux d'indépendance est appliqué, les effectifs théoriques étant tous supérieurs à 5. La p-valeur obtenue est égale à 0,801, largement supérieure au seuil de 5 %. On ne rejette

donc pas l'hypothèse nulle : aucune association statistiquement significative n'est observée entre le genre et le statut matrimonial.

2. Analyse des différences selon le produit

2.1° Niveau d'études selon le produit acheté ([cliquez ici pour consulter l'annexe](#))

À travers le diagramme en barres croisant le produit et le niveau d'études, on observe des différences très marquées entre les modèles. Les clients ayant acheté les modèles TM195 et TM498 appartiennent majoritairement aux catégories 12–14 et 14–16 années d'études, tandis que les acheteurs du modèle TM798 se distinguent fortement : 57,5 % d'entre eux ont un niveau d'études supérieur à 16 ans.



Le test du khi-deux d'indépendance est utilisé pour analyser ce lien. Les effectifs théoriques étant tous supérieurs à 5, les conditions d'application sont respectées.

La p-valeur obtenue est inférieure à $8.376e-16$, ce qui conduit à rejeter très fortement l'hypothèse d'indépendance, car en rejetant l'hypothèse nulle on a seulement une chance très proche de 0 de se tromper. Il existe donc un lien très significatif entre le niveau d'études et le modèle de tapis acheté, le modèle TM798 étant principalement acheté par des clients plus diplômés.

2.2° Condition physique auto-évaluée selon le produit ([cliquez ici pour consulter l'annexe](#))

Le diagramme en barres croisant le produit et la variable Fitness met en évidence des différences nettes entre les modèles. Les acheteurs de TM195 et TM498 s'auto-évaluent majoritairement avec un niveau de forme 3, tandis que les acheteurs de TM798 déclarent massivement une excellente condition physique (niveau 5), représentant plus de 70 % de ce groupe. Le test exact de Fisher avec simulation de la p-valeur est utilisé. La p-valeur obtenue ($\approx 0,0005$) indique un lien statistiquement significatif entre le modèle de tapis acheté et la condition physique auto-évaluée. Le modèle TM798 semble donc particulièrement adapté à des utilisateurs déjà très sportifs.

2.3° Catégorie d'utilisation prévue selon le produit ([cliquez ici pour consulter l'annexe](#))

À travers le diagramme en barres croisant le produit et la catégorie d'utilisation, on observe que les utilisateurs du modèle TM798 se distinguent par une proportion beaucoup plus élevée d'utilisation modérée à élevée, tandis que les modèles TM195 et TM498 sont majoritairement associés à une faible utilisation prévue. Les conditions d'application du test du khi-deux n'étant pas respectées, un test exact de Fisher est à nouveau utilisé. La p-valeur simulée ($\approx$ inférieur à $2.2e-16$) permet de rejeter l'hypothèse d'indépendance. Il existe donc un lien significatif entre le modèle acheté et la fréquence d'utilisation prévue, le TM798 étant associé à une utilisation plus intensive.

2.4° Produit et statut matrimonial ([cliquez ici pour consulter l'annexe](#))

L'analyse descriptive de la distribution du statut matrimonial selon le modèle de tapis de course acheté montre une répartition très similaire entre les différents produits. Quel que soit le modèle considéré (TM195, TM498 ou TM798), environ 60 % des clients sont en couple et 40 % sont célibataires. Aucune différence marquée n'apparaît visuellement entre les modèles.


Afin de tester formellement l'existence d'un lien entre le produit acheté et le statut matrimonial, un test du Khi-deux d'indépendance est réalisé. Les effectifs théoriques étant tous supérieurs à 5, les conditions d'application du test sont respectées. Le test fournit une p-valeur de 0,9605, largement supérieure au seuil de 5 %.

On ne rejette donc pas l'hypothèse nulle d'indépendance : il n'existe pas de lien statistiquement significatif entre le statut matrimonial des clients et le modèle de tapis de course acheté.

Comparaison des clients TM195 et TM498

2.5° Revenu annuel ([cliquez ici pour consulter l'annexe](#))

Les clients ayant acheté le modèle TM498 présentent un revenu moyen légèrement supérieur à ceux ayant acheté le TM195 (48 974 \$ contre 46 418 \$).



le test de Welch met en évidence une différence statistiquement significative entre les deux groupes (p-valeur = 0,093), 9,3% de tomber sur ces valeurs si il n'y avait pas de différence donc assez élevée. On peut donc conclure à une différence significative de revenu entre les clients TM195 et TM498.

2.6° Âge selon TM195 et TM498 ([cliquez ici pour consulter l'annexe](#))

Les âges moyens sont très proches entre les deux groupes (28,9 ans pour TM498 contre 28,6 ans pour TM195). Le test t confirme l'absence de différence significative (p-valeur = 0,767). Les deux produits semblent s'adresser à des clients d'âge comparable.

2.7° Distance hebdomadaire prévue (Miles) selon TM195 et TM498 ([cliquez ici pour consulter l'annexe](#))

Les clients TM498 prévoient en moyenne de parcourir légèrement plus de miles que les clients TM195 (87,9 contre 82,8 miles), mais cette différence n'est pas significative (p-valeur = 0,340). Les niveaux d'activité physique anticipés sont similaires.

2.8° Nombre d'année d'éducation (Education) selon TM195 et TM498 ([cliquez ici pour consulter l'annexe](#))

Le niveau d'éducation moyen est quasiment identique entre les deux groupes (≈ 15 années d'études). Le test de Welch ne révèle aucune différence significative (p-valeur = 0,705).

2.9° Fréquence d'utilisation prévue selon TM195 et TM498 ([cliquez ici pour consulter l'annexe](#))


La fréquence moyenne d'utilisation est très proche (environ 3 utilisations par semaine dans les deux groupes). Le test confirme l'absence de différence significative (pvaleur = 0,878).

Par conséquent, les clients des modèles TM195 et TM498 présentent des profils très similaires, tant en termes socio-démographiques que d'usage prévu. Ces deux modèles semblent donc cibler une population comparable.

Comparaison des clients TM498 et TM798

2.10° Revenu annuel selon les modèles TM498 et TM798 ([cliquez ici pour consulter l'annexe](#))

Les clients du modèle TM798 ont un revenu moyen nettement plus élevé que ceux du TM498 (75 442 contre 48 974\$).



Le test de Welch met en évidence une différence hautement significative (pvaleur < 0,001). Le modèle TM798 est associé à une clientèle beaucoup plus aisée.

2.11° Âge selon les modèles TM498 et TM798 ([cliquez ici pour consulter l'annexe](#))

Les âges moyens sont proches (29,1 ans pour TM798 contre 28,9 ans pour TM498) et la différence n'est pas significative (pvaleur = 0,887). L'âge ne discrimine pas les acheteurs de ces deux modèles.

2.12° Distance hebdomadaire prévue (Miles) selon les modèles TM498 et TM798 ([cliquez ici pour consulter l'annexe](#))

Les clients TM798 prévoient de parcourir en moyenne presque deux fois plus de miles que les clients TM498 (166,9 contre 87,9 miles). Cette différence est statistiquement très significative (pvaleur < 0,001). Les acheteurs du TM798 anticipent une pratique beaucoup plus intensive.

2.13° Niveau d'éducation selon les modèles TM498 et TM798 ([cliquez ici pour consulter l'annexe](#))

Le niveau d'éducation moyen est significativement plus élevé chez les clients TM798 (17,3 années contre 15,1). Le test t confirme une différence significative (pvaleur < 0,001). Le modèle haut de gamme attire une clientèle plus diplômée.

2.14° Fréquence d'utilisation prévue selon les modèles TM498 et TM798 ([cliquez ici pour consulter l'annexe](#))

Les clients TM798 déclarent une fréquence d'utilisation bien plus élevée (4,78 contre 3,07 utilisations par semaine).

Le test de Welch montre une différence très significative (p-valeur < 0,001). Le TM798 est clairement destiné à des utilisateurs réguliers et intensifs.

Synthèse des résultats selon le produit


Les résultats mettent en évidence une segmentation claire des clients selon le modèle acheté :

- TM195 et TM498 : profils proches, clients relativement jeunes, usage modéré, niveaux de revenu et d'éducation similaires.
- TM798 : clientèle distincte, caractérisée par :
 - un revenu significativement plus élevé,
 - un niveau d'éducation supérieur,
 - une fréquence d'utilisation et une activité physique attendue beaucoup plus importantes.

Le modèle TM798 apparaît comme un produit haut de gamme, destiné à une population plus sportive, plus investie dans la pratique et disposant de ressources économiques et éducatives plus élevées, tandis que les modèles TM195 et TM498 ciblent un public plus généraliste.

3. Analyse des liens entre les variables quantitatives

3.1° Analyse générale deux à deux des variables quantitatives continues ([cliquez ici pour consulter l'annexe](#))



Les graphiques montrent :

- Une forte corrélation positive entre l'âge et le revenu (Spearman $\rho \approx 0,68$), indiquant que les clients plus âgés ont généralement un revenu plus élevé, ce qui se reflète sur le nuage de points où les valeurs les plus hautes correspondent aux âges élevés.
- Une corrélation positive modérée entre le revenu et la distance prévue à parcourir (Miles, $\rho \approx 0,36$), suggérant qu'un revenu plus élevé est associé à une distance plus importante.
- Une corrélation quasi nulle entre l'âge et la distance prévue ($\rho \approx 0,03$), indiquant l'absence de lien significatif.

A travers ces graphiques nous ne remarquons qu'aucun d'entre eux n'est dans un cadre linéaire donc on va plutôt opter pour la méthode de Spearman, pour être sûr, car c'est la méthode qui marche la plupart du temps qui nécessite le moins de prérequis.

Corrélation de Spearman ([cliquez ici pour consulter l'annexe](#))

Age-income : Le test de corrélation de Spearman nous renvoie $\rho = 0,683$, $p\text{-value} < 2,2 \times 10^{-16}$. Donc on rejette H_0 , il y a donc une corrélation monotone fortement significative, confirmant le lien positif. Les individus plus âgés gagnent en moyenne davantage.

Income – Miles : Le test de corrélation de Spearman renvoie $\rho \approx 0,36$, $p\text{-value} = 8,83 \times 10^{-7}$. On rejette H_0 , il existe donc une corrélation monotone modérée et significative, indiquant que les clients avec un revenu plus élevé prévoient de parcourir davantage de miles.


Age – Miles : Le test de corrélation de Spearman renvoie $\rho \approx 0,03$, $p\text{-value} = 0,7345$. On ne rejette pas H_0 , la corrélation monotone n'est donc pas significative, suggérant qu'il n'existe pas de lien entre l'âge et la distance prévue.

3.2° Liens entre variables quantitatives au sein de chaque produit ([cliquez ici pour consulter l'annexe](#))


Enfin, des nuages de points accompagnés de coefficients et de tests de corrélation permettent d'étudier les liens entre variables quantitatives selon le produit.

On a observé auparavant une corrélation positive forte et significative entre l'âge et le revenu confirmée par les tests de corrélation de Pearson et de Spearman (p-valeur très faible).


On va maintenant regarder si c'est aussi le cas parmi chaque modèle de tapis acheté.



Le nuage de points met en évidence une augmentation du revenu avec l'âge, quel que soit le modèle de tapis acheté. Pour chacun des trois modèles, à l'aide de la méthode de Spearman, on constate que la corrélation entre l'âge et le revenu est très forte et statistiquement significative : pour le modèle TM798, le coefficient de Spearman est d'environ 0,858 ($p\text{-value} = 1,51 \times 10^{-12}$), pour le modèle TM498, le coefficient de Spearman est d'environ 0,859 ($p\text{-value} < 2,2 \times 10^{-16}$), et pour le modèle TM195, le coefficient de Spearman est d'environ 0,838 ($p\text{-value} < 2,2 \times 10^{-16}$). Dans tous les cas, l'hypothèse nulle d'absence de corrélation monotone est rejetée, indiquant que les clients plus âgés tendent systématiquement à disposer d'un revenu plus élevé, indépendamment du modèle acheté. Cette relation apparaît ainsi particulièrement robuste sur l'ensemble des produits. ([cliquez ici pour consulter l'annexe](#))



À travers ces trois nuages de points, on observe que la relation entre le revenu et la distance prévue à parcourir n'est pas linéaire et qu'aucune corrélation marquée ne se dégage, hormis peut-être une petite corrélation pour le modèle TM798. Pour chacun des modèles de tapis, la corrélation entre le revenu et la distance prévue est faible et statistiquement non significative : pour le modèle TM195, le coefficient de Spearman est d'environ $-0,046$ (p -value = $0,6864$), pour le modèle TM498, le coefficient de Spearman est d'environ $0,012$ (p -value = $0,9295$) et pour le modèle TM798, le coefficient de Spearman est d'environ $0,232$ (p -value = $0,149$). Dans tous les cas, l'hypothèse nulle d'absence de corrélation monotone n'est pas rejetée, indiquant qu'il n'existe pas de lien significatif entre le revenu et la distance prévue, quel que soit le modèle de tapis acheté.



À travers ces trois nuages de points, on observe que la relation entre l'âge et la distance prévue à parcourir n'est pas linéaire et qu'aucune corrélation marquée ne se dégage pour les modèles TM195 et TM498, tandis qu'une corrélation plus visible apparaît pour le modèle TM798. Pour chacun des modèles de tapis, la corrélation entre l'âge et la distance prévue varie et est majoritairement non significative : pour le modèle TM195, le coefficient de Spearman est d'environ $-0,046$ (p -value = $0,6867$), pour le modèle TM498, le coefficient de Spearman est d'environ $-0,066$ (p -value = $0,6177$), et pour le modèle TM798, le coefficient de Spearman est d'environ $0,382$ (p -value = $0,015$). L'hypothèse nulle d'absence de corrélation monotone n'est pas rejetée pour les modèles TM195 et TM498, indiquant l'absence de lien significatif entre l'âge et la distance prévue pour ces modèles. En revanche, pour le modèle TM798, la corrélation est modérée et statistiquement significative, suggérant que les clients plus âgés tendent à prévoir de parcourir davantage de miles.

V) Conclusion générale

L'étude du jeu de données "Cardio Good Fitness" avait pour objectifs de mettre en évidence les différences et similitudes entre les profils des clients selon le genre et le modèle de tapis acheté, ainsi que d'explorer les relations entre les variables quantitatives.

Synthèse des analyses selon le genre

- Les hommes ont un revenu moyen plus élevé que les femmes parcourent en moyenne plus de miles par semaine et déclarent un usage légèrement plus fréquent du tapis.
- Il n'y a pas de différence significative entre hommes et femmes pour l'âge et le niveau d'éducation.
- La répartition des clients selon le produit et la catégorie d'usage diffère selon le genre.

Synthèse des analyses selon le produit

- Les modèles de tapis TM195, TM498 et TM798 présentent des profils de clients distincts :
 - TM798 est principalement acheté par des hommes ayant une éducation plus élevée, un revenu plus important et une utilisation plus intensive du tapis.
 - TM195 et TM498 présentent des profils relativement proches, sans différences significatives d'âge, de Miles ou d'éducation, mais un revenu légèrement plus élevé pour TM498 (non significatif avec $p \approx 0,09$).
- La répartition des clients selon le niveau de forme physique et le niveau d'éducation varie fortement selon le produit.

Synthèse des analyses entre variables quantitatives

- Une forte corrélation positive est observée entre âge et revenu, confirmée par les tests de Pearson et Spearman.
- Une corrélation modérée existe entre revenu et miles parcourus, tandis que l'âge et miles parcourus sont pratiquement indépendants.
- Ces résultats suggèrent que l'expérience financière des clients (âge et revenu) influence davantage leur comportement d'achat que leur âge seul pour la pratique du tapis.

L'analyse montre que le profil des clients varie selon le genre et le modèle de tapis acheté, tant en termes de revenu, d'usage, d'éducation que de niveau de forme physique. Les variables quantitatives révèlent des relations fortes entre âge et revenu, tandis que la distance parcourue est surtout influencée par le revenu et le produit choisi, mais peu par l'âge.

PS : L'IA a été utilisé dans ce compte rendu pour une meilleure formulation des phrases et pour améliorer l'orthographe et la syntaxe.

Nous souhaitons également attirer l'attention sur un point particulier. Nous avons tous les deux, Enzo et Michael, des manières différentes de programmer en R. C'est pourquoi nous avons fait le choix, dans un premier temps, de développer chacun de notre côté la suite du programme. En revanche, pour la rédaction du compte rendu, nous avons mis en commun nos résultats et nos analyses, qui se sont révélés concordants, afin de proposer un compte rendu plus cohérent.

Voici le lien vers nos codes R : <https://github.com/Ecn1234/TestStatCompteRendu/tree/main>

VI) Annexes

1. Analyses univariées

[Cliquer ici pour revenir à la partie I\) Analyse Univariée](#)

1) Product			Gender			Marital Status		
Modalité	n	%	Modalité	n	%	Modalité	n	%
TM195	80	44.4	Femme	76	42.2	Célibataire	73	40.6
TM498	60	33.3	Homme	104	57.8	En couple	107	59.4
TM798	40	22.2						

Fitness			Niv			Usage_cat		
Modalité	n	%	Modalité	n	%	Modalité	n	%
5	31	17.2	>16	27	15	Élevé	9	5.0
4	24	13.3	14-16	90	50	Modéré	69	38.3
3	97	53.9	12-14	63	35	Faible	102	56.7
2	26	14.4						
1	2	1.1						

Variable	Min	Q1	Médiane	Moyenne	Q3	Max
Age	18.00	24.00	26.00	28.79	33.00	50.00
Education	12.00	14.00	16.00	15.57	16.00	21.00
Usage	2.00	3.00	3.00	3.456	4.00	7.00
Income	29 562	44 059	50 597	53 720	58 668	104 581
Miles	21.0	66.0	94.0	103.2	114.8	360.0

2. Analyses bivariées

1. Analyse des différences selon le genre ([cliquez ici pour revenir aux analyses selon le genre](#))

Tableau de p_valeur :

variables	test	p_value
Income selon Gender	t-test Welch	0.004021
Age selon Gender	t-test Welch	0.7071
Miles selon Gender	t-test Welch	0.002467
Education selon Gender	t-test Welch	0.1965
Usage selon Gender	t-test Welch	0.003484

variables	test	p_value
Product selon Gender	Chi2	0.001562
Usage_cat selon Gender	Fisher exact	0.009111
Niv selon Gender	Chi2	0.2165
Fitness selon Gender	Fisher exact	0.01249
MaritalStatus selon Gender	Chi2	0.8005

Tableau de résumé statistique (Variables quantitatives) :

1.1° Statistiques du revenu selon le genre

GENRE	N	MOYENNE	ÉCART-TYPE	Q1	MEDIANE	Q3
FEMME	76	49 829	12 558	42 922	47 754	53 796
HOMME	104	56 563	18 422	45 480	52 302	61 611

1.2° Statistiques de l'âge selon le genre

GENRE	N	MOYENNE	ÉCART-TYPE	Q1	MEDIANE	Q3
FEMME	76	28.6	6.34	24.0	26.5	33.0
HOMME	104	29.0	7.38	23.8	26.0	

1.3° Statistiques des Miles selon le genre

GENRE	N	MOYENNE	ÉCART-TYPE	Q1	MEDIANE	Q3
FEMME	76	90.0	44.8	66	85	100
HOMME	104	113.0	54.7	85	100	141

1.4° Statistiques de l'éducation selon le genre

GENRE	N	MOYENNE	ÉCART-TYPE	Q1	MEDIANE	Q3
FEMME	76	15.4	1.44	14	16	16
HOMME	104	15.7	1.73	14	16	16

1.5° Statistiques de l'usage selon le genre

GENRE	N	MOYENNE	ÉCART-TYPE	Q1	MEDIANE	Q3
FEMME	76	3.18	1.02	2	3	4
HOMME	104	3.65	1.10	3	4	4

Tableau de distribution conditionnelle sachant le genre (Variables qualitatives) :

([cliquez ici pour revenir aux analyses selon le genre](#))

1.4bis° Education (Niv) selon le genre

Groupe	>16	14-16	12-14	Total
Femme	10.5	48.7	40.8	100.0
Homme	18.3	51.0	30.8	100.0

1.5bis° Répartition (%) des Fréquence d'usage en classe (Usage_cla) selon le genre

GENRE	ÉLEVE	MODERE	FAIBLE	TOTAL
FEMME	2.6	27.6	69.7	100.0
HOMME	6.7	46.2	47.1	100.0

1.6° Répartition (%) des modèles achetés selon le genre

GENRE	TM195	TM498	TM798	TOTAL
FEMME	52.6	38.2	9.2	100.0
HOMME	38.5	29.8	31.7	100.0

1.7° Répartition (%) du niveau de Fitness selon le genre


GENRE	5	4	3	2	1	TOTAL
FEMME	7.9	10.5	59.2	21.1	1.3	100.0
HOMME	24.0	15.4	50.0	9.6	1.0	100.0

1.8° Répartition (%) du statut marital selon le genre


GENRE	CELIBATAIRE	EN COUPLE	TOTAL
FEMME	39.5	60.5	100.0
HOMME	41.3	58.7	100.0

Graphiques : ([cliquez ici pour revenir aux analyses selon le genre](#))


1.2° L'âge selon le genre ([cliquez ici pour revenir](#))




1.3° La distance parcourue attendue par semaine (Miles) selon le genre




1.4° Le nombre d'année d'étude (Education) selon le genre




1.4bis° Le nombre d'années d'études en classe (Niv) selon le genre



1.5° Le nombre moyen d'utilisation prévu par semaine (Usage) selon le genre ([cliquez ici pour revenir aux analyses selon le genre](#))




1.5bis° Fréquence d'usage prévue par semaine en classe (Usage_cla) selon le genre




1.6° Modèle de tapis acheté selon le genre



1.7° Condition physique auto-évaluée (Fitness) selon le genre



1.8° Statut matrimonial (Marital Status) selon le genre ([cliquez ici pour revenir aux analyses selon le genre](#))



2. Analyse des différences selon le produit ([cliquez ici pour revenir aux analyses selon le produit](#))

Tableaux de p_valeur :

variables	test	p_value
Product ~ Niv	Chi2	8.376e-16
Product ~ Fitness	Fisher exact	0.0004998
Product ~ Usage_cat	Fisher exact	2.2e-16
Product ~ MaritalStatus	Chi2	0.9605

variables	test	p_value
TM195 vs TM498 ~ Income	t-test Welch	0.09279
TM195 vs TM498 ~ Age	t-test Welch	0.7669
TM195 vs TM498 ~ Miles	t-test Welch	0.3401
TM195 vs TM498 ~ Education	t-test Welch	0.7046
TM195 vs TM498 ~ Usage	t-test Welch	0.8779
TM498 vs TM798 ~ Income	t-test Welch	3.123e-11
TM498 vs TM798 ~ Age	t-test Welch	0.8865
TM498 vs TM798 ~ Miles	t-test Welch	4.268e-10
TM498 vs TM798 ~ Education	t-test Welch	4.747e-10
TM498 vs TM798 ~ Usage	t-test Welch	3.076e-14

Tableau de distribution conditionnelle sachant le genre : ([cliquez ici pour revenir aux analyses selon le produit](#))

2.1° Répartition (%) du niveau d'éducation selon le modèle acheté

MODELE	>16	14-16	12-14	TOTAL
TM195	2.5	53.8	43.8	100.0
TM498	3.3	53.3	43.3	100.0
TM798	57.5	37.5	5.0	

2.2° Répartition (%) du niveau de Fitness selon le modèle acheté

MODELE	5	4	3	2	1	TOTAL
TM195	2.5	11.2	67.5	17.5	1.2	100.0
TM498	0.0	13.3	65.0	20.0	1.7	100.0
TM798	72.5	17.5	10.0	0.0	0.0	100.0

2.3° Répartition (%) des catégories d'usage selon le modèle acheté

MODELE	ÉLEVE	MODERE	FAIBLE	TOTAL
TM195	0.0	30.0	70.0	100.0
TM498	0.0	25.0	75.0	100.0
TM798	22.5	75.0	2.5	100.0

2.4° Répartition (%) du statut marital selon le modèle acheté

MODELE	CELIBATAIRE	EN COUPLE	TOTAL
TM195	40.0	60.0	100.0
TM498	40.0	60.0	100.0
TM798	42.5	57.5	100.0

Tableau de résumé statistique ([cliquez ici pour revenir aux analyses selon le produit](#))

2.5° Statistiques du revenu selon le modèle (sans TM798)

MODELE	N	MOYENNE	ÉCART-TYPE	Q1	MEDIANE	Q3
TM195	80	46 418	9 076	38 658	46 617	53 439
TM498	60	48 974	8 654	44 912	49 460	53 439

2.6° Statistiques de l'âge selon le modèle (sans TM798)

MODELE	N	MOYENNE	ÉCART-TYPE	Q1	MEDIANE	Q3
TM195	80	28.6	7.22	23	26	33.0
TM498	60	28.9	6.65	24	26	33.2

2.7° Statistiques des Miles selon le modèle (sans TM798)

MODELE	N	MOYENNE	ÉCART-TYPE	Q1	MEDIANE	Q3
TM195	80	82.8	28.9	66	85	94
TM498	60	87.9	33.3	64	85	

2.8° Statistiques de l'éducation selon le modèle (sans TM798)

Modèle	n	Moyenne	Écart-type	Q1	Médiane	Q3
TM195	80	15.0	1.22	14	16	16
TM498	60	15.1	1.22	14	16	16

2.9° Statistiques de l'usage selon le modèle (sans TM798)

MODELE	N	MOYENNE	ÉCART-TYPE	Q1	MEDIANE	Q3
TM195	80	3.09	0.783	3	3	4
TM498	60	3.07	0.800	3	3	3.25

2.10° Statistiques du revenu selon le modèle (sans TM195)

Modèle	n	Moyenne	Écart-type	Q1	Médiane	Q3
TM498	60	48 974	8 654	44 912	49 460	53 439
TM798	40	75 442	18 506	58 205	76 568	90 886

2.11° Statistiques de l'âge selon le modèle (sans TM195) ([cliquez ici pour revenir aux analyses selon le produit](#))

MODELE	N	MOYENNE	ÉCART-TYPE	Q1	MEDIANE	Q3
TM498	60	28.9	6.65	24.0	26	33.2
TM798	40	29.1	6.97	24.8	27	30.2

2.12° Statistiques des Miles selon le modèle (sans TM195)

MODELE	N	MOYENNE	ÉCART-TYPE	Q1	MEDIANE	Q3
TM498	60	87.9	33.3	64	85	106
TM798	40	167.0	60.1	120	160	200

2.13° Statistiques de l'éducation selon le modèle (sans TM195)


MODELE	N	MOYENNE	ÉCART-TYPE	Q1	MEDIANE	Q3
TM498	60	15.1	1.22	14	16	16
TM798	40	17.3	1.64	16	18	18

2.14° Statistiques de l'usage selon le modèle (sans TM195)


MODELE	N	MOYENNE	ÉCART-TYPE	Q1	MEDIANE	Q3
TM498	60	3.07	0.800	3	3	3.25
TM798	40	4.78	0.947	4	5	5

Graphiques : ([cliquez ici pour revenir aux analyses selon le produit](#))


2.2° Répartition (%) du niveau de Fitness selon le modèle acheté




2.3° Répartition (%) des catégories d'usage selon le modèle acheté




2.4° Répartition (%) du statut marital selon le modèle acheté




2.6° l'âge selon le modèle (sans TM798) ([cliquez ici pour revenir aux analyses selon le produit](#))




2.7° Distance prévue à parcourir (Miles) selon le modèle (sans TM798)




2.8° Nombre d'années d'études selon le modèle (sans TM798)




2.9° Statistiques de l'usage selon le modèle (sans TM798) ([cliquez ici pour revenir aux analyses selon le produit](#))




2.11° Statistiques de l'âge selon le modèle (sans TM195)




2.12° Statistiques des Miles selon le modèle (sans TM195)



2.13° Statistiques de l'éducation selon le modèle (sans TM195)



2.14° Statistiques de l'usage selon le modèle (sans TM195) ([cliquez ici pour revenir aux analyses selon le produit](#))



3. Analyse des liens entre les variables quantitatives


3.1° Analyse générale deux à deux des variables quantitatives continues

([cliquez ici pour revenir aux analyses entre les variables quantitatives](#))

Tableau Corrélations (Pearson & Spearman) et p-valeurs

Variables	Corr. Pearson	Corr. Spearman	p-valeur Pearson	p-valeur Spearman
Age – Income	0.5134	0.6831	1.708e-13	p-value < 2.2e-16
Age – Miles	0.0366	0.0255	0.6255	0.7345
Income – Miles	0.5435	0.3568	3.194e-15	8.831e-07

Graphique : Visualisation de la matrice de corrélation entre trois variables continues (Âge, Revenu et la distance) avec corplot



3.2° Analyse générale des variables quantitatives continues au sein des produits

([cliquez ici pour revenir aux analyses entre les variables quantitatives](#))

Tableau Corrélations (Pearson & Spearman) et p-valeurs

variables	test	rho	p_value
TM798: Age ~ Income	Spearman correlation	0.8579895	1.506e-12
TM498: Age ~ Income	Spearman correlation	0.85941	2.2e-16
TM195: Age ~ Income	Spearman correlation	0.8376622	2.2e-16

variables	test	rho	p_value
TM195: Miles ~ Income	Spearman correlation	-0.04583624	0.6864
TM498: Miles ~ Income	Spearman correlation	0.01166617	0.9295
TM798: Miles ~ Income	Spearman correlation	0.232459	0.1489

variables	test	rho	p_value
TM195: Age ~ Miles	Spearman correlation	-0.04579539	0.6867
TM498: Age ~ Miles	Spearman correlation	-0.06574459	0.6177
TM798: Age ~ Miles	Spearman correlation	0.3815037	0.01514