

RAPPORT TECHNIQUE INTERMÉDIAIRE

SAE PROJET : ANALYSE STATISTIQUE DU BONHEUR DANS LE MONDE

Titulaires : M. LABIOD, M. GOMEZ-GARCIA

Groupes 11-12

BUT Science des données

Amilia BALIT
Enzo CHEN
Michael DAI
Hugo MA
Reine MANTOUADI KINA



World Happiness Report

Table des matières :

I. Introduction	4
II. Prétraitement.....	5
1. Installation des bibliothèques et du répertoire de travail	5
2. Chargement des données et harmonisation	6
2.1 Harmonisation des noms de colonnes.....	6
2.2 Ajout d'une colonne "année".....	6
3. Fusion des données historiques et récentes	7
4. Création de la variable qualitative : Continent	7
4.1 Harmonisation des noms de pays.....	7
4.2 Jointure des données.....	8
5. Nettoyage des données	8
5.1 Contrôle des types de données	8
5.2 Identification des valeurs manquantes.....	8
5.3 Conversion des types de données	8
5.4 Proportion des valeurs manquantes.....	8
5.5 Gestion des valeurs manquantes.....	9
5.6 Gestion des valeurs aberrantes	Erreur ! Signet non défini.
6. Création de nouvelles variables quantitatives.....	10
6.1 Création de la variable ratio affectif	10
6.2 Création de la variable taux de croissance du PIB	10
7. Recodage des variables numériques.....	10
8. Sélection temporaire de l'échantillon d'étude	11
8.1 Construction des dataframes.....	11
8.2 Définition aléatoire d'un échantillon commun sur toutes les années.....	11
9. Enregistrement du dataframe avec et sans classes	12
III. Exploration des données.....	13
1. Analyses Univariées	13
1.1 À partir de données quantitatives avec classe, groupées (final_data_classes).....	13
1.2 À partir de données quantitatives sans classe, brutes (final_raw_data)	13
2. Analyses Bivariées.....	14
2.1 À partir de données brutes (final_raw_data).....	14
3. Tests statistiques.....	16
3.1 Test de Fisher entre le continent et les autres variables.....	16

3.2 Test de Fisher (ANOVA) entre les variables de <code>final_raw_data</code> et <code>log_gdp_class</code>	16
3.3 Test de corrélation de Pearson entre les variables quantitatives et <i>year</i>	16
3.4 Test de corrélation de Pearson entre les variables quantitatives et <i>Log.GDP.per.capita</i>	17
4. Analyses avec Données Groupées	17
4.1 Diagrammes en barre empilées pour les variables conditionnées par le PIB/habitant	17
4.2 Diagrammes en barre empilées pour les variables conditionnées par le Continent.....	18
4.3 Test du χ^2 entre les variables qualitatives et le Continent.....	18
4.4 Test du χ^2 entre les variables qualitatives et le PIB par habitant en classe.....	19
IV. Conclusion.....	19

I. Introduction

Le bonheur, est un concept qui concerne tout le monde, mais qui est difficile à définir. Emmanuel Kant, un célèbre philosophe, disait que même si tout le monde veut être heureux, personne ne sait vraiment ce qu'il veut exactement. Ce sentiment, difficile à définir, échappe aux mesures objectives.

Cependant, depuis 2012, le **World Happiness Report (WHR)**, lancé par l'ONU, propose une approche concrète, basée sur des critères comme le revenu, la santé et le soutien social. En étudiant ces facteurs, il devient possible de comprendre ce qui influence le bien-être des populations, avec un accent particulier sur des indicateurs comme le PIB par habitant.

Toutefois, la relation directe entre croissance économique et bonheur est-elle systématique dans tous les contextes géographiques et temporels ? C'est cette question qui intéresse les chercheurs et économistes, à travers des données détaillées du **World Happiness Report**, qui incluent des variables économiques, sociales et émotionnelles. Ces données, organisées en trois fichiers Excel, détaillent le bien-être des populations de 165 pays ayant participé au moins une fois aux études du **WHR** entre 2005 et 2024. Elles sont regroupées par pays et par année, et couvrent des indicateurs économiques, sociaux et émotionnels. Les variables clés incluent le *Life Ladder* (score de bonheur subjectif de 0 à 10), le *PIB par habitant en log* (logarithme du PIB par habitant, reflétant la richesse moyenne), le *soutien social* (part de la population pouvant compter sur quelqu'un en cas de difficulté), l'*espérance de vie en bonne santé* (nombre moyen d'années vécues en bonne santé), la *liberté individuelle* (part estimant pouvoir faire librement leurs choix de vie), la *générosité* (part ayant effectué un don ou une action bénévole récemment) et la *perception de la corruption* (part percevant de la corruption dans les institutions). Les *affects positifs* mesurent la fréquence des émotions positives ressenties (plaisir, rire), tandis que les *affects négatifs* évaluent la fréquence des émotions négatives (inquiétude, tristesse).

Notre objectif est d'analyser l'impact du PIB sur le bonheur perçu en se basant sur les données du **World Happiness Report (WHR)** de 2005 à 2024. Pour ce faire, une étape préliminaire essentielle consiste à prétraiter ces données afin de les nettoyer, les harmoniser et les fiabiliser. Ce processus inclut le traitement des valeurs manquantes et aberrantes, la création de nouvelles variables, et l'enrichissement des données si nécessaire, assurant ainsi leur cohérence et minimisant les biais.

Ainsi, la problématique centrale est : **L'augmentation du PIB par habitant entraîne-t-elle une amélioration du bonheur, quel que soit le contexte géographique et temporel ?**

Cette problématique permet d'explorer la relation entre l'évolution économique et le bien-être, en tenant compte des différences culturelles, sociales et géographiques qui influencent ces dynamiques.

Une fois le prétraitement des données achevé, nous pourrons définir un plan d'analyse structuré et commencer à explorer les relations entre les différentes variables, permettant ainsi d'obtenir des résultats fiables et pertinents pour répondre à cette question complexe.

II. Prétraitement

Les opérations effectuées sur les trois fichiers au format Excel (.xls) suivent un processus précis, permettant de préparer les données pour les analyses statistiques ultérieures. Les étapes réalisées sont les suivantes :

1. Charger les bibliothèques nécessaires et configurer l'environnement de travail : Cela comprend l'importation des bibliothèques et des packages nécessaires pour manipuler les données.
2. Charger et préparer les fichiers Excel : Cette étape implique la lecture des fichiers et leur transformation sous un format exploitable, prêt pour les étapes suivantes.
3. Fusionner les fichiers Excel : Il s'agit de regrouper les données provenant des différentes sources en un seul jeu de données cohérent.
4. Effectuer une jointure avec le fichier Pays-Continents : Cette opération ajoute des informations géographiques, permettant ainsi de mieux contextualiser les données selon les continents.
5. Nettoyer et préparer les données finales : Cela inclut la gestion des valeurs manquantes et aberrantes, l'élimination des doublons et l'identification des erreurs potentielles dans les données.
6. Créer de nouvelles variables quantitatives pertinentes pour l'analyse statistique de la problématique.
7. Recoder les variables numériques en classes pour pouvoir effectuer des analyses de données groupées.
8. Enregistrer la base de données finalisée et nettoyée dans un fichier au format Excel (.xlsx).

1. Installation des bibliothèques et du répertoire de travail

La première étape consiste à activer les bibliothèques nécessaires avec la commande **library()**. Les packages sont installés avec **install.packages()** et comprennent :

- **readxl** : Pour lire les fichiers Excel
- **dplyr** : Pour la manipulation et le nettoyage des données
- **writexl** : Pour exporter les résultats au format Excel
- **ggplot2** : Pour réaliser des graphiques
- **RColorBrewer** : Pour générer des palettes de couleurs (utilisé dans notre cas, lors de la réalisation des graphiques)

Après avoir chargé les bibliothèques, il est important de définir le répertoire de travail avec la commande **setwd()**, afin de centraliser les fichiers d'entrée et de sortie, garantissant une organisation efficace.

La commande utilisée est :

```
setwd("Z:/SAE/Projet/Pretraitement")
```

(Attention ! Cette commande devra être modifiée en fonction de l'emplacement du dossier)

2. Chargement des données et harmonisation

Les fichiers sources du **World Happiness Report (WHR)** pour les différentes années sont chargés à l'aide de la commande `read_excel()` du package `readxl`. Ces fichiers sont ensuite convertis en dataframes pour une manipulation efficace dans **R**.

Pour charger les fichiers Excel :

```
excel2023 <- read_excel("data/Data_WHR2023.xls")
excel2024 <- read_excel("data/Data_WHR2024.xls")
excel_hist <- read_excel("data/Data_WHR2005-2022.xls")
```

Les fichiers sont prêts à être utilisés pour les étapes de prétraitement et d'analyse.

2.1 Harmonisation des noms de colonnes

Pour pouvoir comparer les données dans le temps et une fusion entre les fichiers, il est essentiel que les noms de colonnes soient identiques, comme pour les fichiers récents (**2023-2024**), où certaines colonnes ont été renommées.

Nous avons donc renommé les colonnes des fichiers 2023 et 2024 afin qu'elles puissent correspondre aux noms des éditions précédentes. Par exemple, la colonne *Ladder score* devient *Life Ladder*.

Cette harmonisation est réalisée à l'aide de la fonction `rename()` du package `dplyr`.

Pour le fichier 2023 :

```
excel2023 <- excel2023 %>%
  rename("Life Ladder" = "Ladder score",
         "Log GDP per capita" = "Logged GDP per capita",
         "Healthy life expectancy at birth" = "Healthy life expectancy",
         "Freedom to make life choices" = "Freedom to make life choices",
         "Perceptions of corruption" = "Perceptions of corruption")
```

Pour le fichier 2024 :

```
excel2024 <- excel2024 %>%
  rename("Life Ladder" = "Ladder score")
```

2.2 Ajout d'une colonne "année"

Pour les fichiers des années 2023 et 2024, nous avons créé une nouvelle colonne "**année**" afin d'identifier l'année des données, à l'aide de la fonction `mutate()` du package `dplyr`. Cela facilite l'analyse temporelle étant donné que nous distinguons mieux les années et nous permet donc d'assurer l'uniformité avec le fichier historique (**2005-2022**) qui simplifie la fusion avec les données des années précédentes.

Pour le fichier 2023 :

```
excel2023 <- excel2023 %>% mutate(year = 2023)
```

Pour le fichier 2024 :

```
excel2024 <- excel2024 %>% mutate(year = 2024)
```

3. Fusion des données historiques et récentes

Après avoir harmonisé les colonnes, les données des différentes années sont fusionnées pour créer une table unique couvrant la période **2005 à 2024**. Cette fusion est réalisée à l'aide de la fonction `bind_rows()` du package `dplyr`.

Le code utilisé est le suivant :

```
final_data <- bind_rows(excel_hist, excel2023, excel2024)
```

Cela crée une base de données fusionnée.

Pour vérifier que la fusion s'est bien passée, les premières lignes du fichier sont affichées y compris le nom des colonnes : `head(final_data)`

4. Création de la variable qualitative : Continent

Pour enrichir les analyses géographiques, chaque pays est associé à son continent via une table de correspondance externe.

Voici le lien de cette table externe associant chaque pays à son continent : https://www.business-plan-excel.fr/liste-pays-du-monde-excel-capitale-continent/#google_vignette

Ce qui va nous permettre d'alterner les différentes comparaisons entre pays et continent. A partir du lien, un fichier contenant la correspondance entre les pays et leurs continents est chargé :

```
country_continent_mapping <- read_excel("data/PaysContinents.xlsx")
```

4.1 Harmonisation des noms de pays

Les noms des pays sont standardisés pour garantir les jointures entre les datasets. Cela assure que les noms de pays utilisés dans les deux fichiers soient identiques :

```
country_continent_mapping <- country_continent_mapping %>%  
  mutate(Nom_anglais = case_when(  
    Nom_anglais == "United States of America" ~ "united states",  
    Nom_anglais == "United Kingdom of Great Britain..." ~ "united kingdom",  
    Nom_anglais == "Taiwan (Province of China)" ~ "taiwan province of china",  
    [...],  
    TRUE ~ `Nom anglais` # Garder le nom en anglais de départ sinon))
```

La fonction `mutate()` du package `dplyr` permet de créer ou modifier des variables, et `case_when()` permet de définir plusieurs conditions pour effectuer des remplacements conditionnels.

Les noms de pays sont ensuite convertis en minuscules pour éviter les erreurs dues aux différences de majuscule ou minuscule :

```
final_data <- final_data %>%  
  mutate(Country_name = tolower(Country_name))  
  
country_continent_mapping <- country_continent_mapping %>%  
  mutate(Nom_anglais = tolower(Nom_anglais))
```

Ces transformations assurent la cohérence des noms de pays dans les deux tables, facilitant ainsi les jointures futures.

4.2 Jointure des données

Les deux tables sont fusionnées à l'aide d'une jointure à gauche pour lier les pays à leurs continents respectifs :

```
final_data <- final_data %>%  
  left_join(country_continent_mapping, by = c("Country_name" = "Nom_anglais"))
```

La fonction `left_join()` du package `dplyr` permet de lier les données des pays de `final_data` à leurs continents respectifs dans `country_continent_mapping`, comme clé de jointure le nom des pays des 2 dataframes (c'est pourquoi nous avons dans un 1^{er} temps harmonisé les noms des pays).

5. Nettoyage des données

Avant les analyses, il est important de nettoyer les données pour garantir une analyse de qualité. Avant tout, il faut comprendre les différents problèmes (Valeurs manquantes, Type des variables, ...) du dataframe `final_data` à l'aide des étapes de visualisation de sa structure.

5.1 Contrôle des types de données

La fonction `sapply()` applique `class()` à chaque colonne pour vérifier les types de données étant donné que nous ne pouvons pas traiter les données sans connaître leurs types :

```
sapply(final_data, class)
```

5.2 Identification des valeurs manquantes

La fonction `is.na()` détecte les valeurs manquantes, `colSums()` calcule leur nombre par colonne :

```
colSums(is.na(final_data))
```

5.3 Conversion des types de données

5.3.1 Colonnes textuelles en facteurs

Les colonnes contenant des informations qualitatives, comme les noms des pays et des continents, sont converties en facteurs :

```
final_data$Country_name <- as.factor(final_data$Country_name)
```

```
final_data$Continent <- as.factor(final_data$Continent)
```

Le type facteur permet un traitement plus rapide et plus efficace des variables qualitatives dans les fonctions statistiques et graphiques sur R.

5.3.2 Colonnes numériques

Les colonnes numériques sont tous déjà de type numérique (on le sait grâce aux étapes précédentes dont l'étape cf. 5.2 *Contrôle des types de données*), donc il n'est pas nécessaire de les convertir en format numérique.

5.4 Proportion des valeurs manquantes

Pour identifier les colonnes avec des valeurs manquantes dans `final_data`, la proportion de valeurs manquantes par colonne est calculée :

```
na_proportions <- colSums(is.na(final_data)) / nrow(final_data)  
print("Proportions de NA pour chaque colonne :")  
print(na_proportions)
```

`is.na(final_data)` : Crée un tableau logique avec `TRUE` pour les valeurs manquantes.

`colSums(is.na(final_data))` : Compte le nombre de valeurs **NA** par colonne.

La division par `nrow(final_data)` donne la proportion de **NA** pour chaque colonne.

5.5 Gestion des valeurs manquantes

Pour gérer efficacement les valeurs manquantes des variables numériques, nous avons imputé la moyenne par pays lorsque la proportion de valeurs manquantes était inférieure à 15 %, afin de limiter la perte de données. En revanche, les variables présentant un taux de NA trop élevé ont été exclues, car difficilement exploitables.

Le seuil de 15 % a été déterminé après analyse des proportions de valeurs manquantes. La majorité des variables pertinentes avaient moins de 15 % de NA, sauf certaines colonnes du fichier *Data_WHR2023.xls* (celles commençant par *Explained by : ...*), absentes du fichier *Data_WHR2005-2022.xls*, et atteignant jusqu'à 75 % de NA. Ce constat a justifié notre choix de supprimer les colonnes dépassant 15 % de valeurs manquantes, car trop lacunaires pour une analyse fiable.

a. Moins de 15 % de valeurs manquantes : Imputation par groupe ou médiane globale

Les colonnes entre 0 % et 15 % de valeurs manquantes sont imputées par la moyenne des valeurs du même groupe (**country_name**) ou par la médiane globale dans le cas :

```
columns_to_group_impute <- names(na_proportions)[na_proportions <= 0.15]
if (length(columns_to_group_impute) > 0) {
  for (col in columns_to_group_impute) {
    if (col %in% numeric_cols) {
      for (country in unique(final_data$Country name)) {
        country_values <- final_data[final_data$Country name == country, col]
        if (is.numeric(country_values)) {
          country_median <- median(country_values, na.rm = TRUE)
          final_data[final_data$`Country name` == country &
            is.na(final_data[[col]]), col] <- country_median
        }
      }
    }
    global_median <- median(final_data[[col]], na.rm = TRUE)
    final_data[is.na(final_data[[col]]), col] <- global_median
  }
}
```

Ce code traite les colonnes de **final_data** ayant jusqu'à 15 % de valeurs manquantes, en remplaçant ces NA par la moyenne par pays, ou par la moyenne globale si nécessaire. Il commence par identifier ces colonnes et les stocke dans la liste **columns_to_group_impute**. Si cette liste n'est pas vide, le code parcourt chaque colonne numérique concernée, calcule la moyenne par pays (**country_mean**) et remplace les valeurs manquantes par cette moyenne. Si des NA subsistent, ils sont imputés par la moyenne globale de la colonne (**global_mean**). Ce double niveau d'imputation assure des valeurs cohérentes et représentatives, renforçant ainsi la qualité des données pour une analyse fiable.

b. Plus de 15 % de valeurs manquantes : Exclusion des colonnes

Les colonnes avec plus de 15 % de valeurs manquantes sont exclues :

```
columns_to_remove <- names(na_proportions)[na_proportions > 0.15]
```

```
final_data <- final_data[, !(names(final_data) %in% columns_to_remove)]
```

La deuxième ligne met à jour le dataframe **final_data** en conservant uniquement les colonnes qui ne sont pas (le caractère ! permet la négation) listées dans **%in%** vérifie si les éléments à sa gauche se retrouve dans la structure de donnée à sa droite) le vecteur **columns_to_remove**.

6. Création de nouvelles variables quantitatives

6.1 Création de la variable ratio affectif

La variable *ratio affectif* compare les affects positifs et négatifs en divisant la colonne *Positive.affect* par *Negative.affect*. Cette nouvelle variable nous permet d'analyser l'orientation émotionnelle générale des populations d'un pays.

```
final_data$affect_ratio <- final_data$Positive.affect/final_data$Negative.affect
```

Une valeur supérieure à 1 indique une domination des affects positifs.

Un ratio inférieur à 1 montre que les affects négatifs sont plus importants.

6.2 Création de la variable taux de croissance du PIB

La variable *taux de croissance du PIB* est calculé en prenant la différence entre le **PIB par habitant (logarithmique)** de l'année en cours et de l'année précédente, puis en divisant par le PIB par habitant de l'année précédente. Ce calcul permet de suivre l'évolution économique des pays au fil du temps.

```
final_data <- final_data %>%
  arrange(Country.name, year) %>%
  group_by(Country.name) %>%
  mutate(gdp_growth_rate = (Log.GDP.per.capita - lag(Log.GDP.per.capita)) /
    lag(Log.GDP.per.capita)) %>%
  ungroup()
```

La fonction **arrange(Country.name, year)** permet de trier les données par pays et par année. **group_by(Country.name)** regroupe les données par pays pour effectuer les calculs sur chaque pays séparément. **lag(Log.GDP.per.capita)** récupère la valeur du PIB par habitant de l'année précédente. Et enfin **mutate()** crée la nouvelle colonne **gdp_growth_rate** qui contient le taux de croissance du PIB pour chaque pays.

7. Recodage des variables numériques

Les variables quantitatives continues sont converties en catégories distinctes à l'aide de la fonction **cut()**, facilitant ainsi leur analyse avec des données groupées. Ils seront convertis automatiquement en factor. Voici un exemple de recodage pour la variable *Life Ladder*.

```
final_data$life_ladder_class <- cut(final_data$Life.Ladder, breaks = c(1, 3, 4, 6,
7, 7.5, 8.1), labels = c("Très bas [1-3)", "Bas [3-4)", "Moyen [4-6)", "Élevé [6-
7)", "Très élevé [7-7.5)", "Exceptionnel [7.5-8.1)"), include.lowest = TRUE, right
= FALSE)
```

La fonction `cut()` divise une variable continue en catégories distinctes, facilitant ainsi leur analyse descriptive. Voici les principaux paramètres utilisés :

- **breaks** : Définit les bornes des intervalles pour la classification.
- **labels** : Attribue des étiquettes explicites pour chaque intervalle.
- **include.lowest = TRUE** : Inclut la borne inférieure dans le premier intervalle.
- **right = FALSE** : Indique que les intervalles sont fermés à gauche et ouverts à droite.

8. Sélection temporaire de l'échantillon d'étude

8.1 Construction des dataframes

Deux dataframes ont été extraits du jeu de données initial :

- **Quantitatif** : Ce dataframe contient toutes les variables numériques ainsi que les colonnes continent et pays, qui sont maintenues pour l'analyse géographique.

```
final_raw_data <- final_data %>% select(where(is.numeric), continent, pays)
```

➤ **where(is.factor)** : Sélectionne toutes les colonnes dont le type est **factor**.

- **Qualitatif** : Ce dataframe regroupe les variables de type factor et la variable *year*, essentielle pour l'analyse temporelle.

```
final_data_qual <- final_data %>% select(where(is.factor), year)
```

8.2 Définition aléatoire d'un échantillon commun sur toutes les années

Nous avons pris un échantillon aléatoire de pays participants à l'enquête entre 2012 et 2022. Cette sélection d'années est purement aléatoire et n'est liée à aucun critère spécifique :

```
countries_with_complete_years <- final_data %>%  
  filter(year >= 2012, year <= 2022) %>%  
  group_by(Country.name) %>%  
  summarise(years_participated = n_distinct(year)) %>%  
  filter(years_participated == 11)
```

Puis, pour le dataframe des variables quantitatives, nous avons filtré les lignes des pays ayant participé chaque année de 2012 à 2022 :

```
final_raw_data <- final_raw_data %>%  
  filter(Country.name %in% countries_with_complete_years$Country.name &  
  between(year, 2012, 2022)) %>%  
  select(everything())
```

La même opération a été réalisée pour le dataframe des variables qualitatives :

```
final_data_classes <- final_data_classes %>%  
  filter(Country.name %in% countries_with_complete_years$Country.name &  
  between(year, 2012, 2022)) %>%  
  select(everything())
```

Dans la continuité de notre analyse statistique, nous nous concentrerons désormais sur la période 2018 à 2024, afin d'étudier l'impact de la crise sanitaire sur le bonheur. Cette période a été divisée en trois sous-intervalles : 2018-2020 (avant la pandémie), 2020-2022 (pendant) et 2022-2024 (et après). L'objectif est d'observer si la relation entre la richesse d'un pays et le bonheur est restée stable ou si elle a été modifiée par les effets sociaux, économiques et sanitaires de la crise.

Les analyses menées sur les données de 2012 à 2022 avaient pour but de valider notre méthodologie. L'analyse principale portera donc exclusivement sur l'échantillon 2018-2024, plus pertinent pour répondre à notre problématique.

9. Enregistrement du dataframe avec et sans classes

A l'aide de la fonction `write_xlsx`, on crée le fichier *final_raw_data.xlsx* et *final_data_classes.xlsx*, dans le dossier *output* :

```
write_xlsx(final_raw_data, "final_raw_data.xlsx")  
write_xlsx(final_data, "output/final_data_classes.xlsx")
```

Les fichiers *.xlsx* permettent d'avoir les données dans des formats courants pour une gestion plus simple avec l'usage des tableurs tels que Excel.

III. Exploration des données

Pour cette troisième partie du rapport, nous allons préparer tous les éléments prérequis pour la suite des analyses sur l'influence de l'augmentation du PIB sur le bonheur. La préparation est principalement composée de multiples graphiques et de différents tests sur la liaison de 2 variables.

1. Analyses Univariées

1.1 À partir de données quantitatives avec classe, groupées (`final_data_classes`)

Le code suivant génère des graphiques à barres pour toutes les variables catégorielles dans `final_data_classes` (à l'exception de la variable `Country.name`) :

```
for (var in names(final_data_classes)) {
  if (is.factor(final_data_classes[[var]]) && var != "Country.name") {
    print(ggplot(final_data_classes, aes_string(x = var)) +
          geom_bar(fill = "steelblue") +
          theme_minimal() +
          labs(title = paste("Distribution de", var)))
  }
}
```

Ce code parcourt les colonnes de `final_data_classes`, vérifie si elles sont de type **factor**, et génère un graphique avec **ggplot2** pour afficher la distribution des valeurs sous forme de barres à l'aide de la fonction `geom_bar()`.

1.2 À partir de données quantitatives sans classe, brutes (`final_raw_data`)

Le code suivant crée des boîtes à moustaches pour toutes les variables numériques dans `final_raw_data` (à l'exception de `year`) :

```
for (var in names(final_raw_data)) {
  if (is.numeric(final_raw_data[[var]]) && var != "year") {
    print(ggplot(final_raw_data, aes_string(y = var)) +
          geom_boxplot(fill = "steelblue", color = "black", outlier.color = "red",
outlier.shape = 16) +
          theme_minimal() +
          labs(title = paste("Boîte à moustaches de", var), y = var))
  }
}
```

Ce code génère des boîtes à moustaches (`geom_boxplot`) pour chaque colonne numérique, en mettant en évidence les valeurs aberrantes en rouge. Les graphiques sont affichés avec un style minimaliste. Ensuite à l'aide du code ci-dessous, on a pu identifier le nombre de valeurs statistiquement exceptionnelles, en comptant le nombre de valeur au-dessus et en dessous des moustaches :

```
for (col in names(final_raw_data)) {
  if (is.numeric(final_raw_data[[col]])) {
    Q1 <- quantile(final_raw_data[[col]], 0.25, na.rm = TRUE)
    Q3 <- quantile(final_raw_data[[col]], 0.75, na.rm = TRUE)
    IQR <- Q3 - Q1
```

```

moustache_superieure <- Q3 + 1.5 * IQR
moustache_inferieure <- Q1 - 1.5 * IQR
valeurs_au_dessus<-sum(final_raw_data[[col]]>moustache_superieure,na.rm=TRUE)
valeurs_en_dessous<-sum(final_raw_data[[col]]<moustache_inferieure,na.rm=TRUE)
cat("Colonne :", col, "\n")
cat("Nombre de valeurs au-dessus de la moustache supérieure :",
valeurs_au_dessus, "\n")
cat("Nombre de valeurs en-dessous de la moustache inférieure :",
valeurs_en_dessous, "\n")
}
}

```

2. Analyses Bivariées

2.1 À partir de données brutes (final_raw_data)

2.1.1 Boîte à moustaches des variables par continent

Le code suivant génère des boîtes à moustaches pour toutes les variables quantitatives en fonction des continents. Cela permet de visualiser la distribution des valeurs et d'identifier d'éventuelles valeurs aberrantes pour chaque continent :

```

for (var in names(final_raw_data)) {
  if (is.numeric(final_raw_data[[var]]) && var != "year") {
    print(ggplot(final_raw_data, aes_string(x = "Continent", y = var)) +
      geom_boxplot(fill = "steelblue", color = "black", outlier.color = "red",
outlier.shape = 16) +
      theme_minimal() +
      labs(title = paste("Boîte à moustaches de", var, "par continent"), x =
"Continent", y = var) +
      theme(axis.text.x = element_text(angle = 45, hjust = 1))
    )
  }
}

```

Ce graphique permet d'illustrer les variations des différentes variables en fonction des continents. L'axe des X représente les continents, tandis que l'axe des Y représente les variables quantitatives (à l'exception de *year*).

2.1.2 Boîte à moustaches des variables par PIB par habitant

Le code suivant génère des boîtes à moustaches pour chaque variable quantitative, en fonction du PIB par habitant classé en catégories (**log_gdp_class**). Ce graphique permet d'étudier l'impact des différentes classes de PIB sur les autres variables :

```

for (var in names(final_raw_data)) {
  if (is.numeric(final_raw_data[[var]]) && var != "year") {
    temp_data <- final_raw_data %>%
left_join(final_data_classes %>%
select(Country.name, year, log_gdp_class), by = c("Country.name", "year"))
    print(ggplot(temp_data, aes_string(x = "log_gdp_class", y = var)) +
      geom_boxplot(fill = "steelblue", color = "black", outlier.color = "red",
outlier.shape = 16) +
      theme_minimal() +
      labs(title = paste("Boîte à moustaches de", var, "par PIB habitant"), x

```

```
= "log_gdp_class", y = var) +
  theme(axis.text.x = element_text(angle = 45, hjust = 1))
)
}
}
```

Ici, les différentes classes du PIB par habitant sont utilisées comme facteur de division pour observer comment chaque variable change selon la classe de PIB. La visualisation des valeurs aberrantes en rouge aide à identifier les observations extrêmes.

2.1.3 Nuage de points + Droite de régression : Relation entre le PIB par habitant et d'autres variables par continent

Le code suivant génère des nuages de points pour visualiser la relation entre le PIB par habitant et d'autres variables quantitatives, tout en ajoutant une droite de régression linéaire pour observer la tendance générale. Les graphiques sont séparés par continent :

```
variables_y <- names(final_raw_data)[sapply(final_raw_data, is.numeric) &
!names(final_raw_data) %in% c("Log.GDP.per.capita", "year")]
for (var in variables_y) {
  print(ggplot(final_raw_data, aes_string(x = "Log.GDP.per.capita", y = var, color
= "Continent")) +
    geom_point(alpha = 0.6) +
    geom_smooth(method = "lm", se = FALSE, color = "darkgreen") +
    labs(title = paste("Relation entre PIB par habitant et", var, "par
Continent"), x = "Log(GDP per capita)", y = var) +
    theme_minimal()
  )
}
```

Ces graphiques montrent l'association entre le PIB par habitant (logarithmique) et les autres variables pour chaque continent. La droite de régression permet d'évaluer la tendance de la relation.

2.1.4 Nuage de points + Droite de régression : Relation entre PIB par habitant et d'autres variables par année

Cette analyse explore l'évolution de chaque variable par rapport au PIB par habitant pour chaque année, en ajoutant une droite de régression par année pour observer les tendances spécifiques :

```
for (var in variables_y) {
  for (yr in unique(final_raw_data$year)) {
    data_year <- final_raw_data %>%
      filter(year == yr)
    print(ggplot(final_raw_data, aes_string(x = "Log.GDP.per.capita", y = var)) +
      geom_point(alpha = 0.6, color = "orange") +
      geom_smooth(method = "lm", se = FALSE, color = "darkblue") +
      labs(title = paste("Nuage de points pour", var, "par année sachant le
PIB par habitant"), x = "Log(GDP per capita)", y = var) +
      theme_minimal()
    )
  }
}
```

Ici, les variables sont analysées par année, et chaque facette représente l'évolution de la variable selon le PIB par habitant pour cette année spécifique. La droite de régression permet de visualiser l'évolution de la relation.

Cette partie d'analyse bivariable permet de visualiser les relations entre plusieurs variables quantitatives tout en tenant compte de facteurs tels que les continents, le PIB par habitant, et le temps. Ces graphiques et analyses sont essentiels pour comprendre les interactions entre les différentes dimensions de vos données.

3. Tests statistiques

3.1 Test de Fisher entre le continent et les autres variables

Le **test de Fisher** a été utilisé pour analyser si les moyennes des variables quantitatives diffèrent selon les continents. Une **p-valeur** inférieure à 0,05 indique une différence significative :

```
for (var in names(final_raw_data)) {  
  if (is.numeric(final_raw_data[[var]]) && var != "year") {  
    anova_result <- aov(as.formula(paste(var, "~Continent")), data = final_raw_data)  
    p_value <- summary(anova_result)[[1]][1]  
    print(paste("Variable:", var, p_value))  
  }  
}
```

3.2 Test de Fisher (ANOVA) entre les variables de final_raw_data et log_gdp_class

Ce test analyse si les variables numériques varient en fonction des classes de PIB par habitant. Les **p-valeurs** significatives (inférieures à 0,05) indiquent une relation entre les variables et le PIB :

```
for (var in names(final_raw_data)) {  
  if (is.numeric(final_raw_data[[var]]) && var != "year") {  
    temp_data <- final_raw_data %>%  
      left_join(final_data_classes %>%  
        select(Country.name, year, log_gdp_class), by = c("Country.name", "year"))  
    anova_result <- aov(as.formula(paste(var, "~ log_gdp_class")), data = temp_data)  
    p_value <- summary(anova_result)[[1]][1]  
    print(paste("Variable:", var, p_value))  
  }  
}
```

3.3 Test de corrélation de Pearson entre les variables quantitatives et year

Le **test de Pearson** est utilisé pour analyser la corrélation entre chaque variable numérique et l'année. Une **p-valeur** inférieure à 0,05 indique une corrélation significative :

```
for (var in names(final_raw_data)) {  
  if (is.numeric(final_raw_data[[var]]) && var != "year") {  
    cor_result <- cor.test(final_raw_data[[var]], final_raw_data$year, method =  
      "pearson")  
    p_value <- cor_result$p.value  
    print(paste("Variable:", var, "- p-value:", p_value))  
  }  
}
```


3.4 Test de corrélation de Pearson entre les variables quantitatives et *Log.GDP.per.capita*

Ce test mesure la corrélation entre chaque variable et le PIB par habitant. Une **p-valeur** inférieure à 0,05 indique une relation significative :

```
for (var in names(final_raw_data)) {
  if (is.numeric(final_raw_data[[var]]) && var != "year") {
    cor_result <- cor.test(final_raw_data[[var]],
                          final_raw_data$Log.GDP.per.capita,
                          method="pearson")
    p_value <- cor_result$p.value
    print(paste("Variable:", var, "- p-value:", p_value))
  }
}
```

Ces tests permettent de détecter les relations significatives entre les variables, en particulier en fonction du continent, du PIB par habitant et du temps.

4. Analyses avec Données Groupées

4.1 Diagrammes en barre empilées pour les variables conditionnées par le PIB/habitant

Pour analyser la distribution conditionnelle des variables catégorielles en fonction des classes de PIB par habitant (**log_gdp_class**), nous avons utilisé des diagrammes en barre empilées. Ces graphiques montrent la proportion relative des différentes catégories de chaque variable en fonction des classes de PIB par habitant :

```
library(RColorBrewer)
generer_palette_couleurs <- function(num_levels) {
  base_color <- rgb(runif(1, 0.6, 1), runif(1, 0.6, 1), runif(1, 0.6, 1))
  dark_color <- rgb(runif(1, 0, 0.4), runif(1, 0, 0.4), runif(1, 0, 0.4))
  colorRampPalette(c(base_color, dark_color))(num_levels) }
for (var in names(final_data_classes)) {
  if(is.factor(final_data_classes[[var]]) && var!="log_gdp_class" && var!="year"){
    temp_data <- final_data_classes %>%
      count(log_gdp_class, !!sym(var), .drop = FALSE) %>%
      group_by(log_gdp_class) %>%
      mutate(Proportion = n / sum(n)) %>%
      ungroup()
    num_levels <- length(levels(final_data_classes[[var]]))
    random_palette <- generer_palette_couleurs(num_levels)
    if (nrow(temp_data) > 0) {
      print(ggplot(temp_data, aes(x=log_gdp_class, fill=!!sym(var), y=Proportion)) +
            geom_bar(stat = "identity", position = position_fill(reverse = TRUE),
                      color = "black") +
            scale_fill_manual(values = random_palette,
                              guide = guide_legend(reverse = TRUE)) +
            theme_minimal() +
            labs(title = paste("Distribution conditionnelle de", var, "par PIB
                                habitant"), x = "log_gdp_class", y = "Proportion relative") +
            theme(axis.text.x = element_text(angle = 45, hjust = 1))
    )
  }
}
```

Ces graphiques permettent de visualiser comment la répartition des catégories de chaque variable varie en fonction des différentes classes de PIB par habitant.

4.2 Diagrammes en barre empilées pour les variables conditionnées par le Continent

Similairement, des diagrammes en barre empilées ont été créés pour analyser la distribution conditionnelle des variables catégorielles par Continent. Ce graphique permet de comprendre comment les catégories de chaque variable sont réparties selon les continents :

```
for (var in names(final_data_classes)) {
  if(is.factor(final_data_classes[[var]]) && var != "Continent" && var != "year"){
    temp_data <- final_data_classes %>%
      count(Continent, !!sym(var), .drop = FALSE) %>%
      group_by(Continent) %>%
      mutate(Proportion = n / sum(n)) %>%
      ungroup()
    num_levels <- length(levels(final_data_classes[[var]]))
    random_palette <- generer_palette_couleurs(num_levels)
    if (nrow(temp_data) > 0) {
      print(ggplot(temp_data, aes(x=Continent, fill =!! sym(var), y=Proportion)) +
        geom_bar(stat = "identity", position = position_fill(reverse = TRUE),
          color = "black") +
        scale_fill_manual(values = random_palette,
          guide = guide_legend(reverse = TRUE)) +
        theme_minimal() +
        labs(title = paste("Distribution conditionnelle de", var, "par
          Continent"), x = "Continent", y = "Proportion relative") +
        theme(axis.text.x = element_text(angle = 45, hjust = 1))
      )
    }
  }
}
```

Cette analyse permet de comparer la distribution des catégories des différentes variables entre les continents.

4.3 Test du χ^2 entre les variables qualitatives et le Continent

Nous avons utilisé le **test du χ^2** (Khi2) pour tester l'indépendance entre les variables qualitatives (**factor**) et la variable *Continent*. Ce test évalue si la répartition des catégories d'une variable est significativement différente selon les continents :

```
variables <- names(final_data_classes)[sapply(final_data_classes, is.factor)]
for (var in variables) {
  cat("\nTest du Khi2 entre 'Continent' et '", var, "' :\n", sep="")
  contingency_table<-table(final_data_classes$Continent,final_data_classes[[var]])
  test_result <- chisq.test(contingency_table)
  print(test_result)
}
```

Les résultats du test indiquent si la variable est distribuée de manière indépendante du Continent ou s'il existe une association significative. Une **p-valeur** inférieure à 0,05 indique une association significative.

4.4 Test du χ^2 entre les variables qualitatives et le PIB par habitant en classe

Un test similaire a été effectué pour tester l'indépendance entre les variables qualitatives et les classes de PIB par habitant (*log_gdp_class*). Ce test permet de vérifier si les catégories des variables sont distribuées indépendamment des classes de PIB :

```
variables <- names(final_data_classes)[sapply(final_data_classes, is.factor)]
for (var in variables) {
  cat("\nTest du Khi2 entre 'log_gdp_class' et '", var, "' :\n", sep="")
  contingency_table <- table(final_data_classes$log_gdp_class,
    final_data_classes[[var]])
  test_result <- chisq.test(contingency_table)
  print(test_result)
}
```

Les résultats de ce test nous permettent d'évaluer s'il existe une relation significative entre les catégories des variables et les classes de PIB par habitant.

Ces tests et visualisations permettent d'explorer les relations entre les variables catégorielles et les classes de PIB, ainsi qu'entre les variables et les continents, en identifiant des patterns ou des différences significatives.

IV. Conclusion


Le prétraitement des données a impliqué plusieurs étapes essentielles pour garantir leur qualité et leur intégrité, telles que le nettoyage, l'harmonisation et l'enrichissement avec des informations supplémentaires (comme les continents). Ces actions ont permis d'obtenir deux datasets cohérents et prêts pour des analyses approfondies.

Les analyses statistiques ont révélé des relations intéressantes entre les variables, à travers des tests de corrélation, de Fisher, et du Khi2, et ont permis de visualiser les distributions conditionnelles des variables. Ces étapes ont préparé le terrain pour des analyses plus poussées, qui feront l'objet d'un rapport ultérieur.


ANNEXES :

1. Analyse Univariée

A partir de données groupées en classe (final_data_classes) :





A partir de données brutes (final_raw_data) :




2. Analyse Bivariée

A partir de final_data_classes, données groupées en classes :



SAE PROJET : ANALYSE STATISTIQUE DU BONHEUR DANS LE MONDE



SAE PROJET : ANALYSE STATISTIQUE DU BONHEUR DANS LE MONDE

A partir de données groupées (final_data_classes) :

