

SAE Régression sur données réelles

Titulaire : M. José Garcia

Groupe 11

BUT Science des données

Enzo CHEN

Michael DAI

Hugo MA

Reine MANTOUADI KINA



Introduction

La croissance des enfants et des adolescents constitue un indicateur essentiel de la santé et du développement d'une population. Elle reflète à la fois les conditions de vie, les pratiques alimentaires, l'accès aux soins, et les disparités socio-économiques.

Afin de mieux appréhender ces dynamiques à l'échelle mondiale, plusieurs équipes de data scientists spécialisés dans le domaine de la santé ont été mobilisées pour analyser un jeu de données international. Leur mission : explorer et étudier les tailles (en centimètres) d'enfants et d'adolescents âgés de 5 à 19 ans, en lien avec leur âge, leur sexe et leur pays d'origine, dans le but d'établir des courbes de croissance comparables entre les pays.

Pour garantir la représentativité, la méthodologie de l'étude repose sur un échantillonnage rigoureux : dans chaque pays, 200 médecins ont été sélectionnés de manière aléatoire, puis chacun a tiré au sort 20 enfants (10 filles et 10 garçons) pour mesurer leur âge (en années décimales) et leur taille (en centimètres). Ainsi, pour chaque pays, les données de 4 000 enfants ont été collectées, offrant un corpus riche et équilibré pour les analyses statistiques.

Dans le cadre de cette mission, notre groupe a été chargé d'analyser les données provenant de deux pays : les Émirats Arabes Unis et la Nouvelle-Zélande. Le jeu de données mis à notre disposition comprend un total de 8 000 observations, réparties équitablement entre les deux pays (4 000 individus chacun), ainsi qu'entre les sexes (2 000 filles et 2 000 garçons par pays). Pour chaque individu, deux variables ont été enregistrées : la taille (en centimètres) et l'âge (en années décimales), couvrant la tranche d'âge de 5 à 19 ans.

Pour mener à bien cette analyse, en mobilisant des outils statistiques et graphiques (notamment via le langage R), nous avons structuré notre démarche en deux grandes étapes complémentaires :

- **Exploration des données :**

1. **Analyse univariée** : dans un premier temps, nous étudions séparément les variables telles que l'âge ou la taille afin d'observer leur distribution, leur tendance centrale et leur dispersion.
2. **Analyse bivariée** : ensuite, nous croisons les variables (âge, taille, sexe, pays) pour identifier les relations et interactions éventuelles entre elles, notamment les différences de croissance selon le sexe ou le pays.

- **Modélisation statistique :**

1. Nous réaliserons un **ajustement polynomial** des courbes de croissance, en testant différents degrés (de 1 à 4) afin d'identifier le modèle le plus pertinent pour décrire l'évolution de la taille en fonction de l'âge.
2. Nous tracerons ensuite les **courbes de croissance médianes**, ainsi que celles du **premier et troisième quartile**, séparément pour les **filles** et les **garçons** dans **chacun des deux pays**, pour réaliser des comparaisons entre pays et sexe.

I. Exploration des données

Avant d'entamer toute modélisation, il est essentiel de comprendre la structure et les caractéristiques du jeu de données. Cette première étape consiste à analyser les variables disponibles, individuellement puis conjointement, afin de dégager les grandes tendances et éventuelles disparités selon le sexe et le pays.


1. Analyse univariée

L'analyse univariée permet d'examiner séparément chaque variable, afin de décrire leur répartition, leur tendance centrale et leur dispersion. Nous nous intéressons ici plus particulièrement à l'âge et à la taille des individus.

Analyse univariée de la variable âge

Le boxplot de la variable âge montre que la boîte s'étend du premier quartile à 8,515 ans au troisième quartile à 15,445 ans, avec une médiane située à 11,995 ans. Cela signifie que 50 % des individus ont un âge compris entre environ 8,5 et 15,4 ans, la moitié d'entre eux étant plus jeunes que 12 ans.

Boxplot sur la distribution de l'âge (en années décimales)




La médiane est très proche de la moyenne (11,995 ans vs 11,972 ans), ce qui suggère une distribution globalement symétrique. Les moustaches du boxplot s'étirent du minimum de 5,004 ans jusqu'au maximum de 18,999 ans, sans points aberrants ni valeurs extrêmes détectées.

L'écart-type, qui est de 4,03 ans, confirme une dispersion modérée des âges autour de la moyenne. Cette distribution cohérente et équilibrée reflète une bonne représentativité des âges entre 5 et 19 ans dans l'échantillon étudié.

Analyse univariée de la variable taille

Le boxplot de la variable taille montre que la boîte s'étend du premier quartile à 133,4 cm jusqu'au troisième quartile à 163,2 cm, avec une médiane située à 152,1 cm. Cela signifie que 50 % des enfants mesurent entre environ 133 cm et 163 cm, la moitié ayant une taille inférieure ou égale à 152,1 cm.

Boxplot sur la distribution de la taille (en cm)



La moyenne (148,8 cm) est légèrement inférieure à la médiane, ce qui peut indiquer une légère asymétrie vers les tailles plus petites. Les moustaches du boxplot vont du minimum à 107,8 cm au maximum à 188,1 cm, sans présence évidente de valeurs aberrantes, reflétant la diversité des tailles dans la tranche d'âge 5-19 ans.

L'écart-type est de 18,22 cm, ce qui traduit une dispersion importante des tailles, attendue compte tenu de la large gamme d'âges considérée. Ce profil montre une variabilité naturelle liée à la croissance des enfants et adolescents inclus dans l'étude.


2. Analyse bivariable

Après avoir étudié chaque variable individuellement, nous nous intéressons désormais aux relations entre les variables, notamment entre l'âge et la taille. Cette analyse bivariable permet de mieux comprendre comment ces deux dimensions interagissent, et d'identifier des tendances ou corrélations qui éclaireront l'évolution des courbes de croissance.

Taille selon le sexe

Les boxplots de la taille selon le sexe, montrent des différences intéressantes entre les garçons et les filles.

Taille selon le sexe



Pour les **garçons**, la taille varie de 110,3 cm (minimum) à 188,1 cm (maximum). La médiane est de 152,5 cm, légèrement supérieure à celle des filles. Le premier quartile est à 133,8 cm et le troisième quartile à 169,2 cm, ce qui indique que 50 % des garçons mesurent entre environ 134 cm et 169 cm. La moyenne de 151,1 cm est également supérieure à celle des filles, reflétant une taille généralement plus élevée. L'écart-type est de 19,79 cm, ce qui montre une dispersion plus importante des tailles chez les garçons.


Pour les **filles**, la taille varie de 107,8 cm à 173,8 cm, avec une médiane légèrement plus basse à 151,9 cm. Le premier quartile est à 133,0 cm et le troisième quartile à 159,9 cm, indiquant que la moitié des filles mesurent entre environ 133 cm et 160 cm. La moyenne de 146,5 cm est inférieure à celle des garçons, ce qui est cohérent avec les différences physiologiques attendues. L'écart-type est de 16,19 cm, légèrement inférieur à celui des garçons, suggérant une variabilité un peu moindre dans la taille des filles.

Dans l'ensemble, les boxplots confirment que les garçons tendent à être plus grands que les filles dans cette tranche d'âge, avec une plus grande dispersion des tailles.

Le test de Fisher réalisé pour comparer la taille selon le sexe montre une p-valeur très faible, inférieure à 2×10^{-16} et au seuil habituel de 0,05, ce qui indique que la différence moyenne de taille entre garçons et filles est hautement significative sur le plan statistique.

Taille selon le pays

Les boîtes à moustaches montrent que la taille des enfants et adolescents de Nouvelle-Zélande est globalement plus élevée que celle de leurs homologues des Émirats Arabes Unis.



En effet, la médiane est de 154,1 cm en Nouvelle-Zélande contre 151,0 cm aux Émirats Arabes Unis.

De même, la moyenne est plus élevée en Nouvelle-Zélande (150,4 cm) qu'aux Émirats Arabes Unis (147,3 cm).

Les premiers et troisièmes quartiles confirment cette tendance : respectivement 133,7 cm et 165,9 cm pour la Nouvelle-Zélande, contre 133,2 cm et 160,3 cm pour les Émirats Arabes Unis.


Enfin, la dispersion des tailles est plus importante en Nouvelle-Zélande, avec un écart-type de 19,4 cm, contre 16,8 cm aux Émirats Arabes Unis, ce qui suggère une variabilité plus forte dans la population néo-zélandaise, aussi observable en comparant la taille des deux boîtes.

Le test de Fisher montre une p-value extrêmement faible ($3,4e-14$), bien inférieure au seuil habituel de 0,05. Cela indique que la différence de taille moyenne entre les deux pays est statistiquement significative, confirmant que la taille des enfants et adolescents varie réellement selon le pays d'origine.

Taille selon l'âge

Le nuage de points représentant la taille en fonction de l'âge montre une tendance claire à la croissance continue tout au long de la période observée.

Nuage de point de la taille en fonction de l'âge



Entre 6 et 12 ans, les points sont très concentrés et proches les uns des autres, ce qui traduit une faible variabilité de la taille à ces âges, et une taille moyenne similaire pour les filles et les garçons.

À partir de 12 ans, on remarque que les points commencent à s'éparpiller davantage, illustrant une augmentation de la variabilité de la taille au sein des individus, sans doute liée aux différences individuelles dans le rythme de croissance pubertaire. Enfin, vers 18 ans, le nuage de points est le plus dispersé, ce qui témoigne d'une large amplitude de tailles finales atteintes par les adolescents, correspondant à la diversité naturelle de la croissance humaine.

En conclusion, le nuage de points montre que la taille augmente avec l'âge, avec une variabilité plus grande après 12 ans. La corrélation de Pearson est forte (0,93) et la p-value du test est très faible ($< 2.2e-16$), indiquant une association linéaire significative entre âge et taille.


II. Modélisation statistique

Cette étape vise à ajuster des courbes de croissance aux données observées, afin de mieux comprendre les tendances et d'identifier les dynamiques de croissance des enfants et adolescents selon l'âge.

1. AJUSTEMENT POLYNOMIAL DES COURBES DE CROISSANCE

Pour modéliser la taille selon l'âge, nous avons testé des ajustements polynomiaux de degrés 1 à 4, afin de mieux capturer les tendances de croissance.

Courbes de croissance - Ajustement polynomial



Sur ce nuage de points, quatre courbes d'ajustement polynomial sont superposées, chacune correspondant à un modèle de degré différent : linéaire (degré 1, rouge), quadratique (degré 2, violet), cubique (degré 3, vert foncé) et quartique (degré 4, jaune).

On observe que le modèle linéaire, bien que ses coefficients soient tous significatifs (p -valeurs $< 2e-16$) présente le plus fort AIC (52686.04) et un ajustement moins précis, avec un écart type résiduel le plus élevé (6.511868).

Le modèle de degré 2 améliore nettement l'ajustement (AIC = 49640.57), avec tous ses coefficients hautement significatifs (p -valeurs $< 2e-16$). Il représente mieux la tendance de la croissance, réduisant l'écart type des résidus (5.382537).


Le modèle de degré 3 offre un ajustement encore meilleur, affichant le plus faible AIC (49077.08) et un écart-type résiduel réduit (5.195623), et un meilleur coefficient de détermination de 0.9187 contre 0.8723 du modèle linéaire. Bien que le coefficient en âge simple ne soit pas significatif ($p = 0.177$), les termes d'ordre 2 et 3 sont très significatifs ($p < 2e-16$), ce qui témoigne de la complexité réelle de la relation entre âge et taille.

Enfin, le modèle de degré 4 présente un AIC très proche du modèle de degré 3 (49077.93) avec le même coefficient de détermination de 0.9187 mais n'améliore pas réellement l'ajustement.

Certains coefficients, notamment ceux du premier degré et du quatrième degré, ne sont pas significatifs ($p = 0.1735$ et 0.2841), ce qui suggère un sur-ajustement sans gain notable.

Au vu de ces résultats, le modèle polynomial de degré 3 est retenu comme le meilleur compromis entre précision et complexité, en offrant une précision similaire que celui du degré 4 comme le témoigne le coefficient de détermination de 0.9187 identique dans les deux modèles. Il offre la meilleure qualité d'ajustement, validée par l'AIC le plus faible, tout en conservant la majorité de ses coefficients significatifs.

Analyse détaillée et comparaison des résidus des quatre modèles



Modèle de degré 1 – Un ajustement trop simple

Le nuage de points forme une courbe marquée. Cela signifie que le modèle linéaire passe trop loin de certains points, et indique que la relation entre l'âge et la taille ne suit pas un modèle linéaire et donc le modèle ne parvient pas à capturer la tendance de la relation âge et taille.

L'histogramme reflète aussi ce mauvais ajustement : la distribution des résidus est asymétrique, étalée et déséquilibrée, avec des valeurs extrêmes. Cela confirme que le modèle linéaire sous-ajuste fortement les données.

Modèle de degré 2 – Une amélioration partielle

Le nuage de résidus devient un peu moins courbé que le modèle linéaire, mais garde des courbes légères. Le modèle commence à mieux suivre la relation taille-âge, mais certains effets ne sont toujours pas captés.

Du côté de l'histogramme, la distribution des résidus se recentre légèrement autour de zéro. Malgré tout, Une légère asymétrie persiste, signe que le modèle reste encore un imprécis.

Modèle de degré 3 – Un compromis entre complexité et précision

Le nuage de points perd ses courbes des précédents modèles : les résidus deviennent quasi aléatoires, dispersés de manière homogène. C'est ce qu'on attend d'un bon modèle : les erreurs ne suivent plus de schéma.

L'histogramme est également plus convaincant : il tend vers une forme gaussienne centrée, bien équilibrée autour de zéro. Cela montre que les erreurs sont petites, symétriques, et que le modèle atteint un bon équilibre entre complexité et généralisation.

Modèle de degré 4 – Un sur-ajustement

Le nuage de résidus semble aléatoire, sans aucune structure : c'est souvent un très bon signe. Mais attention : cette absence totale de motif peut être le symptôme d'un surajustement, et il s'agit bien du cas ici puisque le modèle de degré 3 possède un plus faible AIC.

L'histogramme, ultra-centré et compact, certes donne une impression de précision extrême, mais il prouve de nouveau ce sur-ajustement.


Par conséquent la progression du degré 1 au degré 4 montre clairement comment un modèle devient plus performant jusqu'à potentiellement devenir trop précis de telle sorte à ce que cela devient un sur-ajustement qui est le cas du modèle de degré 4. Donc le meilleur modèle est celui de degré 3 avec l'AIC le plus faible de 49077.08.

2. Courbes de croissance médiane, premier et troisième quartiles

Nous traçons à présent les courbes de croissance médiane, ainsi que celles du premier et du troisième quartile, séparément pour les filles et les garçons dans chacun des deux pays. Cela permet de comparer l'évolution de la taille selon le sexe et le pays, en distinguant quatre groupes.

Groupe 1 : Boys – UAE

Courbes de croissance médiane, Q1 et Q3 - Boys (UAE)




Pour les garçons résidant aux Émirats Arabes Unis, les courbes de croissance révèlent une progression régulière de la taille en fonction de l'âge. La courbe médiane en rouge montre une augmentation continue, passant de 119,3 cm entre 5 et 6 ans à 171,1 cm entre 18 et 19 ans. Cette évolution reflète une croissance linéaire dans l'enfance, suivie d'un ralentissement progressif à l'adolescence, jusqu'à atteindre un plateau à l'approche de l'âge adulte. La courbe du premier quartile suit une trajectoire parallèle à celle de la médiane, allant de 117,2 cm à 168,4 cm sur la même période. Elle indique que 25 % des garçons ont une taille inférieure à ces valeurs à chaque tranche d'âge. De son côté, la courbe du troisième quartile débute à 120,9 cm et atteint 173 cm à 18-19 ans, représentant les 25 % les plus grands. L'écart entre le premier et le troisième quartile reste relativement stable de 5 à 14 ans, avant de diminuer légèrement vers la fin de l'adolescence, ce qui suggère une tendance à l'homogénéisation des tailles à l'approche de l'âge adulte.

Groupe 2 : Girls – UAE

Chez les filles vivant aux Émirats Arabes Unis, les courbes de croissance traduisent également une progression continue de la taille avec l'âge, mais avec un profil légèrement différent de celui observé chez les garçons. La courbe médiane montre une nette augmentation de la taille entre 5 et 13 ans, passant de 114,6 cm à 155,8 cm, ce qui témoigne d'une croissance rapide durant l'enfance et le début de l'adolescence. À partir de 13 ans, la croissance ralentit progressivement jusqu'à se stabiliser autour de 158,6 cm vers 18-19 ans.


Courbes de croissance médiane, Q1 et Q3 - Girls (UAE)



La courbe du premier quartile suit une tendance parallèle, débutant à 112,7 cm pour les 5-6 ans et atteignant environ 155,6 cm à la fin de l'adolescence, indiquant que 25 % des filles mesurent en dessous de ces valeurs à chaque tranche d'âge. De son côté, le troisième quartile commence à 116,4 cm et atteint 161,1 cm à 18-19 ans, représentant les 25 % les plus grandes. L'écart interquartile se maintient relativement constant au fil des années, suggérant une croissance assez homogène au sein de cette population féminine, avec toutefois un léger resserrement des tailles après 16 ans, signe d'une stabilisation de la croissance à l'approche de l'âge adulte.

Groupe 3 : Boys - New Zealand

Courbes de croissance médiane, Q1 et Q3 - Boys (New Zealand)




Chez les garçons néo-zélandais, la croissance se distingue par une progression marquée et soutenue de la taille tout au long de l'enfance et de l'adolescence. La courbe médiane indique une augmentation régulière de la taille de 117,6 cm à l'âge de 5-6 ans jusqu'à un pic d'environ 177,7 cm à 17-18 ans, avec une légère baisse observée après cet âge, suggérant une stabilisation de la croissance. Cette trajectoire est caractéristique d'une puberté plus tardive

mais également plus prolongée que dans les autres groupes. Le premier quartile suit une évolution comparable, allant de 114,7 cm à 174,4 cm entre 5 et 18 ans, ce qui signifie que 25 % des garçons mesurent moins que cette valeur à chaque tranche d'âge. Le troisième quartile, quant à lui, progresse de 119,4 cm à 180,2 cm, traduisant une croissance importante chez les individus les plus grands de cet échantillon. L'écart interquartile, relativement large en fin d'adolescence, révèle une certaine hétérogénéité dans la vitesse ou le moment de la croissance pubertaire parmi les garçons néo-zélandais, ce qui est typique d'une population où la maturation peut être très variable d'un individu à l'autre.

Groupe 4 : Girls - New Zealand

Courbes de croissance médiane, Q1 et Q3 - Girls (New Zealand)




Chez les filles néo-zélandaises (dernier groupe), les trois courbes montrent une croissance rapide entre 5 et 13 ans, suivie d'un ralentissement progressif jusqu'à 19 ans. La courbe médiane, qui représente la taille centrale de la population, illustre parfaitement cette dynamique : elle reflète la taille typique d'une fille à chaque tranche d'âge et met en évidence le pic de croissance pubertaire suivi d'un plateau autour de 165 cm dès 16 ans indiquant la fin de la croissance staturale.

L'écart entre le premier quartile (Q1) et le troisième quartile (Q3) reste modéré et relativement constant à partir de 10-11 ans, ce qui reflète une croissance assez homogène entre les individus. La courbe du premier quartile indique que 25 % des filles de chaque groupe d'âge mesurent en dessous de cette valeur, tandis que la courbe du troisième quartile montre que 25 % d'entre elles sont au-dessus de la taille correspondante. Cet intervalle interquartile donne une bonne indication de la dispersion staturale au sein de la population. On constate par exemple qu'à 13 ans, 50 % des filles se situent entre environ 158 cm (Q1) et 163,5 cm (Q3), soit une variation relativement resserrée.

Ce resserrement de l'écart entre Q1 et Q3 à partir de l'adolescence traduit un alignement progressif des trajectoires de croissance, avec moins de disparités qu'aux âges plus jeunes.

Comparaison des courbes de médiane entre les 4 groupes

Le graphique comparant les courbes médianes des tailles entre les quatre groupes révèle des différences significatives liées au sexe et au pays d'origine.



En ce qui concerne le sexe, les garçons, tant en Nouvelle-Zélande qu'aux Émirats arabes unis, présentent systématiquement des tailles médianes supérieures à celles des filles, conformément aux différences biologiques habituelles dans les trajectoires de croissance. Par exemple, en Nouvelle-Zélande, les garçons atteignent une taille médiane d'environ 177 cm à 17-18 ans, tandis que les filles plafonnent autour de 164 cm, témoignant d'une puberté plus tardive et prolongée chez les garçons. Aux Émirats arabes unis, cette différence se maintient, avec une taille médiane maximale d'environ 171 cm chez les garçons contre 159 cm chez les filles.

Les comparaisons entre pays mettent également en évidence des disparités notables. On constate que les garçons néo-zélandais affichent la courbe médiane la plus élevée, avec une croissance soutenue tout au long de l'enfance et de l'adolescence, culminant autour de 177 cm vers 17-18 ans. En revanche, les garçons des Émirats arabes unis présentent une courbe légèrement plus basse, traduisant une taille médiane globalement inférieure à chaque tranche d'âge. Chez les filles, la courbe médiane des néo-zélandaises est également plus élevée que celle des filles des Émirats arabes unis, avec une croissance rapide avant 13 ans, suivie d'un ralentissement progressif, et un plateau autour de 164 cm en fin d'adolescence contre environ 159 cm pour les Émiraties.

Ces observations soulignent l'impact conjoint des facteurs biologiques liés au sexe et des facteurs environnementaux ou génétiques associés au pays d'origine sur les trajectoires de croissance. Elles montrent aussi que, malgré des dynamiques de croissance similaires, la taille moyenne finale varie sensiblement selon le contexte géographique et le sexe, témoignant de la complexité des déterminants de la croissance staturale chez l'enfant et l'adolescent.

Conclusion

L'analyse approfondie des données de taille et d'âge d'enfants et adolescents âgés de 5 à 19 ans issus des Émirats Arabes Unis et de Nouvelle-Zélande met en lumière plusieurs constats essentiels concernant la croissance staturale, en tenant compte des variables sexe et pays d'origine.

Dans un premier temps, l'exploration des données a révélé des informations clés, notamment que la taille moyenne des garçons est généralement supérieure à celle des filles, conformément aux différences biologiques habituelles. On observe également une plus grande dispersion des tailles chez les garçons, témoignant d'une variabilité individuelle plus importante à ces âges.

Dans un deuxième temps, la modélisation statistique a permis de dégager les grandes tendances de l'évolution de la taille en fonction de l'âge, à travers la construction des courbes de croissance. L'ajustement polynomial a montré que le modèle de degré trois offrait la meilleure représentation de la relation non linéaire entre l'âge et la taille, en capturant les phases complexes de la croissance pubertaire et post-pubertaire.

Les courbes de croissance médianes, accompagnées des intervalles interquartiles, ont ensuite été établies pour chaque sexe et chaque pays. Elles mettent en évidence des dynamiques spécifiques : une croissance plus homogène chez les filles, une progression plus étalée chez les garçons, ainsi que des trajectoires distinctes selon le contexte géographique.

Enfin, la comparaison des courbes médianes confirme que les garçons sont systématiquement plus grands que les filles, et que les enfants néo-zélandais, en particulier les garçons, présentent des tailles supérieures à celles de leurs homologues des Émirats arabes unis. À 17-18 ans, l'écart atteint environ 6 cm. Ces résultats soulignent l'influence conjointe du sexe et de l'environnement sur les trajectoires de croissance.

Summary

This study is part of a global project on growth curves in children aged 5 to 19. Our analysis focused on two countries: New Zealand and the United Arab Emirates. A descriptive exploration of the data revealed that boys are consistently taller on average than girls, with greater individual variability observed among boys. We then modeled height growth as a function of age using polynomial regressions. The cubic model proved to be the most appropriate for capturing the nonlinear relationship between age and height, particularly during puberty. Growth curves were constructed for each sex and country, including the median as well as the first and third quartiles. Finally, comparison between the two countries showed that New Zealand children, especially boys, generally have higher median heights. At ages 17–18, the difference reaches approximately 6 cm in favor of New Zealand boys compared to their Emirati counterparts. These findings highlight the combined influence of sex and geographical context on growth trajectories.